

作品编码： 509403

农作物种植策略的优化决策模型
——基于鲁棒优化与动态调整的综合方法
研究报告

学校名称： 常州工学院

研究主题： 农作物种植策略优化与决策支持系统

应用领域： 农业决策优化与乡村振兴

成员姓名： 许子祺

指导老师： 许子祺

摘要

本文面向乡村振兴背景下的 2024–2030 年农业种植优化决策问题，重点研究在异构耕地（露天/大棚）与严格农艺规则（轮作、防重茬、作物-地块适宜性）约束下，如何实现收益最大化与风险控制的平衡。基于地块、作物、单产、成本、价格与销量上限等数据，以 2023 年为基期，分别构建确定性与不确定性情景下的决策优化模型，通过情景仿真与稳健性评估，提出可执行的年—季—地块—作物配置方案。

针对**问题一（确定性最优规划）**：建立以七年期累计净收益最大化为目标的**多周期混合整数规划（Multi-period MIP）**模型。以“年-季-地块-作物”种植面积为连续决策，配合表示“是否在地块上种植某作物”的二进制变量来刻画分散度与重茬控制。约束涵盖：（1）地块面积与季节可用性；（2）作物-地块适宜性与大棚专属作物限制；（3）同季同地块不交叠；（4）禁止重茬与豆科作物轮作周期；（5）年度/季节劳作与产销匹配。目标函数以销售收入减去种植、管理等成本为净收益，必要时可引入轻度惩罚项平滑地块过度分散。采用 Gurobi 对规模化模型求解，并通过“基准价—销量足额”与“超产导致价格折减”的两类情景进行对比，得到可直接执行的七年滚动种植表。该方案在保持农艺可行性的前提下实现收益最大化，并兼顾作物结构与地块连贯性。

针对**问题二（不确定性与保底收益）**：考虑单产、价格、成本与销量上限等参数在区间内波动，引入**鲁棒优化**框架构造不确定集。为兼顾可解释性与可解性，采用盒式/预算不确定集（可设保守度 Γ 控制同时“出最坏值”的参数个数），并推导收益项与产销约束的鲁棒对偶重构，获得与原 MIP 同类的确定性等价模型。鲁棒解的含义是：在所有允许的参数扰动下，方案始终可行且净收益下界最大。我们比较不同 Γ 下的“保底收益—乐观收益”权衡曲线，并报告方案在最不利情景下的净收益下界、可行性比、以及相对确定性解的“后悔值”（Regret）。数值结果显示：在中等保守度下，最坏情景收益显著抬升，乐观情景收益仅小幅让渡。

针对**问题三（价格反馈与动态决策）**：在考虑供给—价格弹性与信息逐年更新的背景下，构建**多阶段滚动优化策略**。我们以年为阶段，在每年获得实际产量/价格/销量信息后更新模型参数，并基于未来多情景（由历史波动与专家区间生成）进行再优化，输出下一年度的种植方案；为刻画下行风险偏好，引入 CVaR（条件在险价值）度量，将“收益分布尾部”纳入目标。算法流程为：“参数更新—情景生成—含 CVaR 的两阶段近似/期望-下偏联合目标—解 MIP—推进到下一年”，并通过蒙特卡洛外层仿真评估策略的稳健性、保底收益与分位表现。对比显示：滚动 +CVaR 策略在价格大幅波动与销量受限情境下能显著减少收益尾部损失，同时维持较高的期望收益。

评估方面，我们从三类指标衡量方案质量：（1）经济性：七年累计净收益、年均收益、收益波动率、CVaR@95%、最坏情景收益下界；（2）可行性与农艺性：重

茬与轮作约束满足率、作物/地块切换频率、地块分散度；(3) 稳健性：对价格/单产/销量扰动的灵敏度、鲁棒预算 Γ -收益前沿、方案在 1000 次蒙特卡洛中的失效率与分位收益。计算上，通过变量预筛、适宜性削减和季节-地块分解启发式降低模型规模，主问题在分钟级可解，鲁棒对偶后的模型规模可控；滚动优化在年度尺度重复求解，整体时间可满足实际编制与滚动修订的需要。在数据预处理中，统一单位口径、修正异常价格点并对少量缺失值实施分布一致性填补，以提升求解稳定性与评估公平性。

结论上，本文提出的“确定性 MIP^[1]—鲁棒优化—滚动 +CVaR^[2]”递进式框架能够兼顾收益最大化、保底收益与实施可行性：确定性解提供高质量基线与结构性启示；鲁棒解在不确定环境下给予可靠下界；滚动 +CVaR 策略在动态与高波动市场中取得优异的下行风险控制。该方法体系具备可复制性与扩展性，可在引入价格阶梯、产能扩张与基础设施投资等扩展情景时无缝衔接。

关键词：多周期混合整数规划；鲁棒优化；预算不确定集；CVaR；滚动优化；轮作约束

关键词：

目 录

插图清单.....	III
附表清单.....	IV
0.1 问题重述.....	IV
0.1.1 任务概述.....	IV
0.1.2 数据与预处理.....	IV
0.1.3 问题拆解.....	IV
0.1.4 模型轮廓与求解思路.....	V
0.1.5 评价指标与结果呈现.....	V
0.1.6 极简符号表.....	V
0.2 假设与符号.....	V
0.2.1 数据口径与单位.....	V
0.2.2 基本假设.....	VI
0.2.3 农艺规则与可行域补充.....	VI
0.2.4 价格与销量机制.....	VI
0.2.5 符号表（扩展）.....	VII
0.3 确定性最优化模型（问题一）.....	1
0.3.1 问题背景与建模思路.....	1
0.3.2 模型与约束.....	2
0.3.3 数据与口径.....	7
0.3.4 数值实验与结果解读.....	9
0.3.5 求解流程与可解性.....	10
0.3.6 讨论与扩展（可选）.....	10
0.3.7 答案与输出.....	11
0.3.8 工程落地与实施计划.....	11
0.4 不确定性与保底收益（问题二）.....	13
0.4.1 背景与建模框架.....	13
0.4.2 鲁棒目标与等价重构.....	14
0.4.3 约束体系与求解流程.....	17
0.4.4 实验设计与评测指标.....	18
0.4.5 参数标定与 Gamma 选择.....	19

0.4.6 数值结果与业务解读.....	22
0.4.7 实施建议与复核.....	29
第 1 章 论文主要部分的写法	33
1.1 价格反馈与动态滚动优化策略	33
1.1.1 模型动机与设定.....	33
1.1.2 价格—供给—销量反馈与识别.....	35
1.1.3 情景生成与参数更新.....	36
1.1.4 含 CVaR 的两阶段滚动优化模型	37
1.1.5 求解策略与算法流程.....	38
1.1.6 数值实验与对比分析.....	39
1.1.7 敏感性与稳健性讨论.....	40
1.1.8 本章小结.....	42
1.2 模型综合评价与对比分析	43
1.2.1 实验设置.....	43
1.2.2 评价指标.....	43
1.2.3 结果呈现与对比.....	43
1.2.4 讨论与管理启示.....	47
1.2.5 本章小结.....	47
参考文献.....	48

插图清单

图 1	作物结构随时间的堆叠面积图（示意）	2
图 2	资源利用对比：跨期折线 vs. 季一设施热力图	3
图 3	销量与销量上限对照（示意）	5
图 4	作物切换成本/频次热力图（示意）	6
图 5	主要作物：面积与收益属性的并排对比	8
图 6	收益表现：曲线与分布的联合呈现	9
图 7	参数敏感性雷达图（示意）	12
图 8	参数标定流程（ Γ -Grid 与帕累托过滤）	20
图 9	收益与风险概览：年度收益曲线与后悔值 ECDF 对比	25
图 10	Γ 影响下的收益前沿与结构形态对比	26
图 11	稳健性对约束违约与资源占用的影响：违约率与资源利用并排对比	27
图 12	鲁棒方案切换频次热力图。跨季/跨作物的跳变明显减少，执行路径更平滑，切换成本与不确定性暴露同步下降。	28
图 13	关键因素对收益波动的敏感性（鲁棒 vs. 确定性）。两方案对主要因素的影响排序基本一致，但鲁棒方案对负向扰动的灵敏度更低。	29
图 1.1	基线收入—供给曲线示意（用于刻画价格弹性与容量上限对总收入的影响）	33
图 1.2	销量—产能的配比关系示意（容量约束导致的瓶颈区间）	35
图 1.3	确定性方案在历史波动下的收益分布（作为滚动优化的对照基线）	36
图 1.4	地块—作物切换热图（利于识别滚动优化中需重点稳定的子区）	37
图 1.5	鲁棒预算与后悔值的并排对比	38
图 1.6	滚动策略相关图的并排整合展示	40
图 1.7	敏感性与风险的并排对比（基线 vs 滚动 + CVaR）	41
图 1.8	年度单产与资源使用的并排对比	42
图 1.9	收益分布与尾部对比（确定性 vs 滚动基线）	44
图 1.10	鲁棒前沿与后悔值并排对比（第二章 vs 第三章）	44
图 1.11	资源利用率对比（确定性 vs 鲁棒 vs 滚动）	45
图 1.12	结构演变与切换稳定性对比	45
图 1.13	敏感性与约束违约风险对比	46
图 1.14	价格—供给—容量反馈与拐点效应	47

附表清单

表 1	主要符号与参数定义（问题一）	7
表 2	数据口径映射表示例（与 C 题及附件口径对齐）	9
表 3	作物产销与收益（模板）	11
表 4	Model 2 图表与生成脚本的对应关系（标签保持不变）	23
表 5	本章新增符号与口径对照表	30
表 6	阈值指引（示例， X/Y 由业务设定）	30

0.1 问题重述

0.1.1 任务概述

在乡村振兴背景下，需要在 2024–2030 年七年期内，为若干异构耕地（露天/大棚）按季节选择作物并安排种植面积，在满足农艺规则（轮作、防重茬、作物—地块适宜性）与产销约束的前提下，最大化长期经济收益并控制不确定性风险。题目要求分别解决：- 问题一（确定性最优化）：在确定性参数下获得七年累计净收益最大化的可执行方案；- 问题二（不确定性与保底收益）：在区间扰动下，通过鲁棒优化获得“最坏情景收益”下界尽可能大的方案；- 问题三（价格反馈与动态决策）：考虑供给—价格弹性与逐年信息滚动更新，形成风险可控的滚动优化策略，并评估尾部损失（CVaR）。

0.1.2 数据与预处理

根据题面及附件提供的数据，包含：地块编号、面积、季节可用性、大棚标识、作物—地块适宜性；作物单产、价格、成本、销量上限以及（若有）超产价格折减机制或价格区间。以 2023 年为基期。为保证求解与评估稳定性：统一单位口径；识别并修正显著异常价格点；对少量缺失值按分布一致性进行温和填补；保留季节与地块层面的结构特征。

0.1.3 问题拆解

- 确定性（问题一）：构建多周期混合整数规划（Multi-period MIP），以“年—季—地块—作物”面积为连续变量，配合作物选择二元变量控制同季不交叠、重茬与分散度；目标为七年累计净收益最大化。- 鲁棒（问题二）：考虑单产、价格、成

本、销量上限的区间波动，引入盒式/预算不确定集（保守度 Γ ）并进行鲁棒对偶重构，使目标成为“最坏情景”净收益下界最大。- 动态（问题三）：在供给—价格弹性与信息逐年更新背景下，采用“参数更新—情景生成—再优化”的滚动框架，并以 CVaR@95% 控制尾部风险，比较与问题一/二的收益—风险权衡。

0.1.4 模型轮廓与求解思路

核心约束包括：地块面积与季节可用性、作物—地块适宜性与大棚限制、同季同地块不交叠、禁止重茬与轮作周期、产销匹配与销量上限、（若给定）超产价格折减。采用商用求解器（如 Gurobi）对确定性与鲁棒等价模型求解；动态部分以年度滚动方式迭代，外层蒙特卡洛评估稳健性与分位表现。通过变量预筛、适宜性削减与季节—地块分解启发式降低规模，保证分钟级可解或年度级迭代可用。

0.1.5 评价指标与结果呈现

- 经济性：七年累计/年均收益、收益波动率、CVaR@95%、最坏情景收益下界；
- 农艺与实施性：重茬/轮作约束满足率、作物/地块切换频率、地块分散度；
- 稳健性：对价格/单产/销量扰动的灵敏度、 Γ —收益前沿、蒙特卡洛失效率与分位收益。
结果以“年/季/地块/作物/面积/产量/销量/收入/成本/净收益”等表格与关键曲线呈现。

0.1.6 极简符号表

为避免与“假设与符号”（见第0.2章）及“符号表（扩展）”（见第0.2.5章）的详细内容重复，本节仅保留最小必要条目以便快速阅读：

集合（最小）： $\mathcal{T}$ 、 $\mathcal{S}$ 、 $\mathcal{I}$ 、 $\mathcal{K}$ ；如涉及大棚与轮作，使用 $\mathcal{G}$ 、 $\mathcal{K}_{\text{green}}$ 、 $\mathcal{K}_{\text{legume}}$ 。

变量（最小）：面积 x_{tsik} 、选择 z_{tsik} 、销量 q_{tsk} 、年净收益 r_t 。

参数（最小）：面积上限 A_{is} 、适宜性 η_{isk} 、单产 y_{tsk} 、单价 p_{tsk} 、成本 c_{tsk} 、销量上限 u_{tsk} 。

其余（如折价系数 ϕ_{tsk} 、轮作间隔 L_k 、鲁棒度 Γ 、CVaR 置信水平 α 等）请见第0.2.5节。

0.2 假设与符号

0.2.1 数据口径与单位

为保证模型求解与结果可比，采用如下统一口径：

- 面积单位：亩（或公顷，本文以“亩”为例）；产量单位：kg；价格单位：元/kg；

成本单位：元/亩；销量单位：kg。

- 时标：年 $t \in \mathcal{T} = \{2024, \dots, 2030\}$ ，季 $s \in \mathcal{S}$ （如春/夏/秋/冬，或早/晚季，依数据口径）。
- 地块 $i \in \mathcal{I}$ ，其中大棚地块子集 $\mathcal{G} \subseteq \mathcal{I}$ ；作物 $k \in \mathcal{K}$ 。
- 以 2023 年为基期，成本、价格、单产等参数若无特殊说明均以名义值计。

0.2.2 基本假设

1. 地块可用性：给定 A_{is} 表示地块 i 在季 s 的可用面积；季节-地块的不可用状态用 $A_{is} = 0$ 表示。
2. 作物适宜性： $\eta_{isk} \in \{0, 1\}$ 指示作物 k 在地块 i 的季 s 是否可种（已将大棚专属限制并入 η_{isk} 或集合 $\mathcal{K}_{\text{green}}$ ）。
3. 产量线性化：单位面积产量 y_{tsk} 给定，季节与年份可变；总产量等于 $y_{tsk} \sum_i x_{tsik}$ 。
4. 价格/成本：确定性场景下单价 p_{tsk} 、单位面积成本 c_{tsk} 为常数；销量上限 u_{tsk} 给定。
5. 市场可售：若无特殊折价机制，先以“基准价—销量上限”框架求解；超产折价若存在在评价节（或扩展模型）中再引入。
6. 劳作资源与机械约束：如未提供详表，先不显式建模，后续可按“年/季最大可耕面积或工时”扩展。

0.2.3 农艺规则与可行域补充

- 同季不重叠：同一地块同一季仅允许一种作物。
- 重茬与轮作：同一地块禁止相邻季对同一作物的连续种植；豆科等作物遵循最小轮作间隔 L_k （如 $L_k \in \{2, 3\}$ 季）。
- 大棚限制：若 $i \notin \mathcal{G}$ ，则 $\mathcal{K}_{\text{green}}$ 中作物在该地块不可种；已体现在 η_{isk} 中。
- 面积上限： $0 \leq x_{tsik} \leq A_{is}$ 且受适宜性 η_{isk} 与二元选择变量联动。

0.2.4 价格与销量机制

- 确定性： $0 \leq q_{tsk} \leq u_{tsk}$ ，收入为 $p_{tsk} q_{tsk}$ ；若 q_{tsk} 受产量约束，则 $q_{tsk} \leq \sum_i y_{tsk} x_{tsik}$ 。
- 可选折价（扩展）：当 $\sum_i y_{tsk} x_{tsik} > u_{tsk}$ ，超出部分按折减系数 $\phi_{tsk} \in (0, 1)$ 定价： $p_{tsk}^{\text{eff}} = p_{tsk}$ （不超时），超出部分单价 $\phi_{tsk} p_{tsk}$ 。

0.2.5 符号表（扩展）

为便于查阅，这里在“极简符号表”的基础上给出更完整的记号分组与说明（单位/口径已与本章前述约定一致）。

1 集合与索引

$\mathcal{T}$	年集合（2024–2030）
$\mathcal{S}$	季节集合（按数据口径定义顺序，如春 → 夏 → 秋 → 冬）
$\mathcal{I}$	地块集合
$\mathcal{K}$	作物集合
$\mathcal{G} \subseteq \mathcal{I}$	大棚地块子集（如适用）
$\mathcal{K}_{\text{green}} \subseteq \mathcal{K}$	仅允许在大棚种植的作物集合（如适用）
$\mathcal{K}_{\text{legume}} \subseteq \mathcal{K}$	需遵循最小轮作间隔的作物集合（如豆科）
$\mathcal{W}$	情景集合（用于滚动/仿真/鲁棒评估）

说明：跨年滚动时季节序按数据给定口径循环推进。

2 决策变量

$x_{tsik} \geq 0$	年 t 、季 s 、地块 i 上作物 k 的种植面积（亩）
$z_{tsik} \in \{0, 1\}$	是否在 (t, s, i) 上选择作物 k （控制同季不重叠/重茬）
$q_{tsk} \geq 0$	年 t 、季 s 作物 k 的销售量（kg）
r_t	年 t 净收益（统计用）

3 参数

A_{is}	地块 i 在季 s 可用面积（亩）
$\eta_{isk} \in \{0, 1\}$	作物 k 在地块 i 季 s 的适宜性指示
y_{tsk}	单产（kg/亩）
p_{tsk}	单价（元/kg）
c_{tsk}	单位面积成本（元/亩，含种植/管理等）
u_{tsk}	销量上限（kg）
L_k	作物 k 的最小轮作间隔（以季计）
$\phi_{tsk} \in (0, 1)$	超产折价系数（可选，若启用折价机制）
Γ	预算不确定集保守度（鲁棒优化中使用）
$\alpha \in (0, 1)$	CVaR 置信水平（如 0.95，用于尾部风险度量）

注：若题面未启用折价与鲁棒/动态机制，可将 ϕ_{tsk} 、 Γ 、 α 视为未激活参数；数据来源见题目附件与数据预处理节。

0.3 确定性最优化模型（问题一）

0.3.1 问题背景与建模思路

针对确定性最优化问题，本章基于明确的数据口径与农艺规则，构建以“年一季一地块一作物”为核心索引的多期混合整数规划模型。我们以经营净收益最大化为目标，并用“面积不超一同季不重叠一作物适宜一产销匹配一轮作与重茬抑制一资源瓶颈一切换成本”七类约束依次收紧可行域。相应地，通过结构类图（如figures 1 and 5(a)）展示作物结构与地块配置；绩效类图（如figures 6(a) and 6(b)）反映收益水平与分布特征；资源占用类图（如figures 2(a), 2(b) and 3）分析瓶颈限制与产销匹配关系。本章作为后续鲁棒与滚动章节的基线，用于对比不同风险设定下的收益—风险权衡。

0.3.1.1 问题分析（与赛题对齐）

本节通过“数据源—建模要素—约束体系”的逻辑链条分析问题结构：首先，**地块异质性与设施属性**决定了“能不能种、能种多少、需要多少资源”。露天与大棚在季节可用性、气象适应性及设施/工时投入上差异明显。我们以地块—季节—作物三维的适宜性指标 η_{isk} 控制“可/不可种”，以季节—作物维度的资源系数 h_{sk} 刻画单位面积对设施/工时的占用强度，从而在约束层面将题面中的农艺规则与产能现实转化为可计算的边界条件。

其次，**多季耦合与轮作规则**使问题天然具有时序相关性：同一地块同一季不能重复种多种作物（同季不重叠），相邻季或窗口内对同一作物的重复栽培会触发重茬问题，需要最小轮作间隔 L_k 来保证土壤与病虫风险的可控。这些都通过式（7）—（8）进行刚性约束，使解在时间维度上保持农艺合规。

再次，**产销匹配与销量上限**塑造了“可卖即价值”的逻辑。即便产量充足，如果受限于销量上限 u_{tsk} 或渠道与冷链能力，则可售量仍受天花板约束。我们用式（5）—（6）联合限定销量，使模型在产品—渠道两端达成一致，避免“纸面盈利而实际积压”的不现实解。

同时，**资源瓶颈与执行复杂度**是影响落地的关键。旺季设施/工时（式（9））易成为瓶颈，若不对切换频度进行抑制，将导致频繁换茬和管理复杂度陡增。我们引入切换成本（式（10））将管理扰动货币化，使得“稳定但略低收益”与“频繁调整但潜在高收益”在目标中得到权衡，提升解的可实施性。

在**目标的经济含义**方面，年度净收益可分解为“价格×销量”的营业净额减去“单位面积成本×面积”的种植成本，再扣除切换成本。这一结构贴合一体化经营的财务口径，便于与企业现有的管理报表对接，并通过图6(a)、图6(b)进行直

观呈现。

最后，**规模与难度**来自于“多背包/多分配—跨期耦合”的组合结构。本问题为多期 MIP，理论上 NP-难。工程上通过变量预筛、约束收紧、松弛热启动与割的增量注入等策略，实现分钟级可解，同时保留与题面一致的决策颗粒度与可解释性。

0.3.2 模型与约束




图 1 作物结构随时间的堆叠面积图（示意）

0.3.2.1 决策变量

核心变量围绕“种什么、种多少、卖多少、赚多少、怎么切”。其中， $x_{tsik} \geq 0$ 表示年 t 、季 s 、地块 i 上种植作物 k 的面积（亩），体现排产与资源占用； $z_{tsik} \in \{0, 1\}$ 作为二元选择变量，保障同一地块同一季的唯一作物选择，并与 x_{tsik} 通过式（3）建立联动，防止违规叠加； $q_{tsk} \geq 0$ 表示作物 k 在年 t 、季 s 的实际销量（kg），受产量与销量上限共同约束； r_t 汇总年度净收益，作为跨年对比与策略评估的核心指标； $w_{t,s,i,k \rightarrow k'} \in \{0, 1\}$ 指示相邻季在同一地块从作物 k 切至 k' 的发生，用于在式（10）中计提切换成本。上述变量与后续约束、目标函数共同构成“可行—可解—可落地”的决策闭环。

0.3.2.2 目标函数

目标为最大化七年累计净收益 $\sum_{t \in \mathcal{T}} r_t$ 。上述目标以“经营净收益最大化”为主线。直观地， r_t 将“收入（价格 $\times$ 销量）”与“成本（单位面积成本 $\times$ 面积）”在年度维度汇总，刻画了管理者最关心的经营结果。本章不引入额外的风险度量，仅

以必要的数学形式作为辅助说明；鲁棒与滚动优化的风险刻画将在后续章节对比展开。




图2 资源利用对比：跨期折线 vs. 季—设施热力图

0.3.2.3 场景与敏感性设计（文字化）

为帮助业务方理解结构变化与收益起伏的来源，我们针对关键假设进行场景与敏感性梳理（不额外给出新公式）：当**销量上限收紧**时，优势作物会受到“顶到头”的抑制，可售量触及 u_{tsk} 的上界，导致收益均值下降且波动收敛；当**销量上限放松**时，渠道释放带来结构向优势作物倾斜，收益曲线整体抬升，见图6(a)的对比。

若**价格上行或单产提升**，营业净额按“价格 $\times$ 销量”放大，收益曲线整体上移；若变动具有季节性，解会在不同季节间重新分配面积与销量，实现结构顺势调整（参考图1）。

在**资源紧张**情境下，模型倾向于向“单位资源回报更高”的作物集中，以满足式（9）；当**资源宽松**时，解更分散且切换更频繁，但需要通过式（10）中的成本抑制过度换茬，以保障执行可行。

关于**切换成本**，较高的切换成本会提升结构稳定性与可操作性，但可能牺牲部分收益；较低成本提高灵活度，也带来更高的换线压力与组织成本，需要在收益与可执行性之间取得平衡（均由式（10）量化）。上述场景均可在数据口径与参数侧直接调节，并可参见附录算法（列表.2、列表.3）的实现要点，以便复核口径并保证结论的可复现与可审计。

1 业务解读与取值逻辑

为便于非技术读者理解，上述变量可作如下直观解释： x_{tsik} 可理解为“在何时（ t, s ）、何地（ i ）种了多少（面积）什么作物（ k ）”，直接决定资源投入与产销基础；如遇不相容地块—作物或季节不可用情形， x_{tsik} 将被约束为 0。 z_{tsik} 保证同

一地块同一季只选一种作物，并与 x_{tsik} 的联立约束共同避免重复与违规搭配。 q_{tsk} 则对应“当季实际卖出多少”，受限于可供产量与销量上限，是产销协同后的出销量。 r_t 汇总全年经营净收益，便于跨年与跨策略的可比评价，是管理者最敏感的绩效指标。

0.3.2.4 约束条件

为减少公式堆叠，本节仅保留关键式，常识性取值域与链接条件以文字化方式给出；相同含义的不等式不重复展示。

1 地块可用性与同季不重叠

$$\sum_{k \in \mathcal{K}} x_{tsik} \leq A_{is}, \quad \forall t, s, i, \quad (1)$$

$$\sum_{k \in \mathcal{K}} z_{tsik} \leq 1, \quad \forall t, s, i, \quad (2)$$

$$x_{tsik} \leq A_{is} z_{tsik}, \quad \forall t, s, i, k. \quad (3)$$

2 作物—地块适宜性与大棚限制

$$x_{tsik} \leq \eta_{isk} A_{is}, \quad \forall t, s, i, k. \quad (4)$$

3 产销匹配与销量上限

$$q_{tsk} \leq \sum_{i \in \mathcal{I}} y_{tsk} x_{tsik}, \quad \forall t, s, k, \quad (5)$$

$$0 \leq q_{tsk} \leq u_{tsk}, \quad \forall t, s, k. \quad (6)$$




图3 销量与销量上限对照 (示意)

4 重茬与轮作 (示例化建模)

为避免同一地块连续季对同一作物重茬, 给出简化约束 (可按季定义顺序索引 s^+ 为下一季):

$$z_{tsik} + z_{ts^+ik} \leq 1, \quad \forall t, i, k, \quad (7)$$

若作物 $k \in \mathcal{K}_{\text{legume}}$ 需满足最小轮作间隔 L_k (以季计), 可用窗口化不等式近似:

$$\sum_{\Delta=0}^{L_k-1} z_{t,s \oplus \Delta, i, k} \leq 1, \quad \forall t, s, i, k \in \mathcal{K}_{\text{legume}}, \quad (8)$$

其中符号 $s \oplus \Delta$ 表示季节序的循环推进 (跨年时 t 同步推进, 实际实现时按具体季序展开)。

5 资源与切换成本扩展

考虑设施/工时资源与作物切换成本, 以增强可实施性:

$$\sum_{i \in I} \sum_{k \in \mathcal{K}} h_{sk} x_{tsik} \leq R_s, \quad \forall t, s, \quad (9)$$

并且 $x_{t,s,i,k} \geq 0$, $z_{t,s,i,k} \in \{0, 1\}$; x 与 z 的关联已由式 (3) 给出。为表述切换成本, 引入表示切换的二元变量 (可由 z 的相邻季差异线性化得到) 并累加进入净收益:

$$r_t = \underbrace{\sum_{s,k} p_{tsk} q_{tsk} - \sum_{s,i,k} c_{tsk} x_{tsik}}_{\text{营业净额}} - \underbrace{\sum_{s,i,k,k'} \kappa_{k \rightarrow k'} w_{t,s,i,k \rightarrow k'}}_{\text{切换成本}}, \quad (10)$$

其中 $w_{t,s,i,k \rightarrow k'} \in \{0,1\}$ 指示在地块 i 上由作物 k 切至 k' 的发生, 可用标准“邻接-大 M /补变量”构造线性化近似, 或通过季节展开与“唯一选择”约束得到保守刻画。

为避免使用大 M , 采用邻接线性化 (在唯一选择约束 (2) 成立的前提下, 无需额外大常数)。其核心为: 若相邻季从 k 切至 k' , 则

$$w_{t,s,i,k \rightarrow k'} \geq z_{t,s,i,k} + z_{t,s^+,i,k'} - 1, \quad \forall t, s, i, k \neq k'. \quad (11)$$

同时满足两个上界条件 $w_{t,s,i,k \rightarrow k'} \leq z_{t,s,i,k}$ 与 $w_{t,s,i,k \rightarrow k'} \leq z_{t,s^+,i,k'}$ (为减少公式铺陈, 此处不再展示)。




图 4 作物切换成本/频次热力图 (示意)

6 可实施性与业务规则对应

式 (1) – (8) 共同确保“面积不超、同季不重叠、作物匹配、产销相符、轮作合规”。式 (9) 则将设施/工时这一关键瓶颈显式化, 使解能直接指导生产编排; 式 (10) 将“从甲作物切换到乙作物”的隐性成本货币化, 避免频繁切换带来的生产扰动。

0.3.2.5 复核清单（问题一）

为便于复核，本章目标与主要约束小结如下（符号与口径见第0.2章）：为便于快速核对，我们以文字化方式归纳关键点：目标为最大化七年累计净收益 $\sum_{t \in \mathcal{T}} r_t$ （见“模型与约束”），其中 r_t 按式（10）定义并包含切换成本项。地块与同季不重叠依照式（1）–（3）、（2）执行，作物—地块适宜性由式（4）保证。产销匹配遵循式（5）–（6），确保销量不超过可售上限且与产量一致。重茬与轮作通过式（7）–（8）进行时序约束；资源瓶颈由式（9）显式限制。关于切换，邻接线性化式（11）用于计算并约束切换事件，使成本核算与执行语义一致。

上述条目可与“数据与口径”小节的参数表与图表一并复核，确保口径一致与实现可追溯。

0.3.3 数据与口径

0.3.3.1 符号与参数定义

为便于检索，汇总主要符号与参数（示例化节选，可与数据表一致扩展）：

表 1 主要符号与参数定义（问题一）

符号	维度	含义
$\mathcal{T}, \mathcal{S}, \mathcal{I}, \mathcal{K}$	集合	年度、季节、地块、作物索引集合
A_{is}	i, s	地块 i 在季节 s 的可用面积（亩）
$\eta_{isk} \in \{0, 1\}$	i, s, k	作物 k 在地块 i 、季节 s 的适宜性（1=可种）
y_{tsk}	t, s, k	单位面积产量（kg/亩）
u_{tsk}	t, s, k	销量上限（kg）
p_{tsk}	t, s, k	销售价（元/kg）
c_{tsk}	t, s, k	变动成本（元/亩），含种子/肥药/水电/人工等
h_{sk}	s, k	设施资源用量系数（小时/亩或标准棚时/亩）
R_s	s	季节 s 可用设施/工时总额
$\kappa_{k \rightarrow k'}$	k, k'	作物切换成本（元/亩），从 k 切换至 k'




图 5 主要作物：面积与收益属性的并排对比

0.3.3.2 数据预处理与口径统一


为确保求解稳定与评估公平，数据在建模前进行标准化处理：首先统一单位体系：面积以“亩”为准，单产以“kg/亩”，价格以“元/kg”，成本以“元/亩”。随后针对价格与单产中的极端点，采用箱线图规则或分位数截断进行稳健修正，在不过度平滑的前提下保留趋势结构。对于缺失数据，优先使用“同作物 × 同季节 × 相近年份”的历史分布进行一致性填补；当样本稀疏时，辅以相邻季滑动均值与小幅扰动的拼接方案，避免人为引入偏差。最后对 p_{tsk} , y_{tsk} , c_{tsk} 的时间粒度进行口径对齐，并对节假日或天气冲击导致的短期异常做温和平滑处理，保证后续求解的稳定性与结果的可比较性。

0.3.3.3 数据清洗细则


结合比赛题目“C 题”（见项目根目录‘C 题.pdf’）与附件数据（‘附件 1.xlsx’、‘附件 2.xlsx’、‘附件 3/’），为确保可比性与可解性，采用如下清洗与口径规则（仅以文字说明，不新增公式）：我们首先完成字段与口径映射：统一作物名称、季节口径与度量单位，解决同物异名问题并对重点作物进行人工复核。针对缺失值，遵循“同作物 × 同季节 × 相近年份”的优先级进行插补；当样本稀疏时，采用相邻季滑动均值并叠加小幅噪声以保持总体分布形态，同时对可能的结构性断点进行标注，便于结果解释。在异常值处理上，对价格与单产使用分位法（如 IQR）稳健裁剪；若极端取值来源有据（如极端天气或节假日冲击），予以保留并在可视化中加注释。销量上限从‘附件 2.xlsx’抽取并与历史出清量比对校验；资源/工时口径按‘附件 1.xlsx’与题面统一至季节粒度。最后，以“年-季-地块-作物”为主键进行一致性与主外键检查，消解重复/冲突记录；清洗脚本固定随机种子与版本号，输出“清洗日志/差异报告”，并保留原始备份与映射字典以实现可追溯。

表 2 数据口径映射表示例（与 C 题及附件口径对齐）

字段	来源（题面/附件）	单位	备注/处理
作物名称	附件 1/2	无	统一命名（建立别名词典）；人工复核重点作物
面积	附件 1	亩	与地块可用面积 A_{is} 对齐，异常值回退为中位数
单产	附件 3 或历史台账	kg/亩	分位裁剪，缺失用同作物同季历史插补
价格	附件 2/市场数据	元/kg	假期/极端天气点保留并加注释
变动成本	附件 1/题面口径	元/亩	细项合并为 c_{tsk} ，口径统一到季
销量上限	附件 2	kg	与式（6）一致，历史出清比对
资源/工时	附件 1/题面口径	小时/亩	汇总为季节资源 R_s 与系数 h_{sk}



(a) 年度收益曲线对比（含 CVaR 置信带）：
确定性 vs. 鲁棒 vs. 滚动 + CVaR



(b) 年度净收益分布（示意）

图 6 收益表现：曲线与分布的联合呈现

0.3.4 数值实验与结果解读

基于题面与附件数据（见“数据预处理与口径统一”与“数据清洗细则”），本章在确定性参数下得到的基线解，从以下维度进行解读：我们先从**结构演化**入手：图1 展示跨期的作物结构变化轨迹，配合图5(a) 的累计面积对比，可以识别结构性主力作物与补充作物的角色与边界。

其次考察**资源占用**：图2(a) 与图2(b) 分别刻画季节资源利用率与“季一设施”占用热点，帮助我们直观定位瓶颈季并识别潜在冗余，从而为后续的资源配置与排产细化提供依据。

在**产销约束**层面，图3 给出了销量与销量上限的对照，可用来检视式（6）的紧致性与潜在放宽空间，避免出现“多产不多卖”的资源浪费。

关于**收益表现**，图6(a)对比了确定性、鲁棒与滚动 + CVaR 的年度收益曲线，为后文风险设定的对比提供基线；图6(b)呈现年度净收益分布，有助于观察尾部特征与偏度。

最后从**敏感性**角度，图7汇总关键参数的敏感性结果，呼应前述“场景与敏感性设计”的口径设定，便于业务侧理解“哪些参数最值得盯、调、控”。

0.3.5 求解流程与可解性

为保证“可行—可解—可复现”，我们将求解流程组织为可操作的工程管线。首先读入附件数据，按“数据预处理与口径统一”与“数据清洗细则”完成口径对齐与质量控制。随后在变量生成阶段，仅对满足 $\eta_{isk} = 1$ 且 $A_{is} > 0$ 的组合生成 (x, z) ，并对 $u_{tsk} = 0$ 的作物一季不生成 q_{tsk} ，以削减问题规模。之后加入主要约束（式（1）–（8）、（9）、（11）），必要时叠加轻量正则以改善数值稳定性；目标函数按式（10）构造，并开展供求一致性检查，剔除全零 u_{tsk} 或 y_{tsk} 的无效组合。

在优化策略上，先求解“无切换成本与无轮作”的松弛问题获取热启动解，再逐步引入切换与轮作约束并继续优化，以平衡收敛速度与解的可行性。求解器参数设置上，建议 MIPGap 约 1%、时限分钟级，并启用启发式与并行以提高效率；最终导出 (x^*, z^*, q^*) 与 r_t^* 进入可视化与报告环节，实现从数据到答案的全链路闭环。

1 轮作/切换割的增量加入

为降低初始规模，可采用“违反检测—补充割”的方式渐进收紧：先在基础可行解上扫描每个 (i, k) 的时间序列，记录冲突窗口；为冲突窗口追加相应不等式（如式（7）或窗口和式（8）的实例化），重新优化直至无违反。

2 正确性与复杂度（文字化）

邻接线性化（11）在“唯一选择”约束（2）成立时与“相邻两季选择不同作物即视为发生切换”的语义等价；本问题为带时序耦合与资源一轮作约束的多期 MIP，工程上依托变量预筛、约束收紧、热启动与割的增量注入，可在分钟级完成求解并生成业务可读结果。

0.3.6 讨论与扩展（可选）

在不改变问题一主线的前提下，可加入以下平滑正则项以提升可实施性：为提升排产的平滑性与可执行性，可在目标中加入结构分散度惩罚（参数 $\lambda_{\text{div}} \geq 0$ ），例如对地块一季的 HHI 指数加权，从而抑制过度集中；也可通过显式闲置资源变

量 $\xi_s \geq 0$ 与约束 $\sum_{i,k} h_{sk} x_{tsik} + \xi_s = R_s$, 在目标中加入 $-\lambda_{\text{idle}} \sum_s \xi_s$ 以避免长期低利用率。此外, 若题面允许, 可引入“超产折价机制”, 将超过 u_{tsk} 的部分按折减价 $\phi_{tsk} p_{tsk}$ 计入收入, 通过分段线性与容量平衡实现近似, 保证激励与约束一致。

0.3.7 答案与输出

为便于评审与落地, 将最优解组织为三类结果表: 我们建议输出三类结果以支撑复核与实施: 其一为**地块—季—作物安排表**, 逐项列出 (t, s, i) 的作物选择与面积 (由 z^*, x^* 给出), 用于直接下发排产; 其二为**作物产销与收益表**, 按 (t, s, k) 汇总产量、销量与收入 (由 x^*, q^* 与 y, p 计算), 用于利润核算与渠道衔接; 其三为**资源利用与切换表**, 展示季节资源利用率与地块作物切换事件 (由 x^*, u^* 推得), 用于检视瓶颈季与切换负荷。为适配论文排版, 给出简化模板 (示例列项, 可按实际字段扩展):

表 3 作物产销与收益 (模板)

年 t	季 s	作物 k	产量 (kg)	销量 (kg)	收入 (元)
……由解 (x^*, q^*) 与参数 (y, p) 计算并填充……					

1 复现说明

为避免长路径与手动断行导致的排版松散, 改用左对齐小号体列出脚本—图号对应关系 (示例化条目, 可按需扩展):

```
python/figures_model1/model1_stack_area.py 对应图 1
python/figures_model1/model1_area_by_crop_bar.py 对应图 5(a)
python/figures_model1/model1_resource_util_line.py 对应图 2(a)
python/figures_model1/model1_resource_heatmap.py 对应图 2(b)
python/figures_model1/model1_sales_vs_capacity.py 对应图 3
python/figures_model1/revenue_curve.py 对应图 6(a)
python/figures_model1/model1_profit_distribution.py 对应图 6(b)
python/figures_model1/model1_sensitivity_spider.py 对应图 7
python/figures_model1/model1_yield_bar.py 对应图 5(b)
python/figures_model1/model1_switch_heatmap.py 对应图 4
```

运行环境依赖 Python 3 与常见科学计算栈 (如 numpy、pandas、matplotlib)。脚本按“数据预处理与口径统一/数据清洗细则”的口径读取参数与结果, 输出至 figures/ 目录以便论文直接引用。


0.3.8 工程落地与实施计划

为将模型转化为可执行的年度/季度计划, 建议: 在数据侧, 建立覆盖“题面—附件—参数”的 ETL 流水线与口径校验机制, 并固化“清洗日志/差异报告”的输出; 在模型侧, 形成标准化的求解容器 (参数—模型—求解—导出), 保留求解

日志与 Gap 收敛曲线以便审计；在业务侧，按“地块—季—作物—面积”的粒度下发排产清单，并为切换事件制定工序 SOP，预估换茬耗时与费用；在复盘侧，季度化检视“资源瓶颈—结构调整—收益偏差”，据此迭代校准 y, p, c, u 与 κ 的取值区间，使模型长期贴合经营现实。

1 可解性要点

模型为多期混合整数规划（连续变量 x, q 与二元变量 z ）。为提升可解性与鲁棒性：我们采用“先减再精”的策略提升可解性：通过变量预筛剔除 $\eta_{isk} = 0$ 或 $A_{is} = 0$ 的组合，并对 $u_{tsk} = 0$ 的作物—季不生成销售变量，显著压缩规模；在约束层面对（1）–（4）增加显式上界与强化不等式，缩小松弛域体积；求解过程中以地块—季为块进行分解，先解无轮作/资源耦合的松弛，再将联络约束作为割逐步加入，向主问题热启动；求解器参数建议 MIPGap 约 1%、时限分钟级，对切换成本采用分层权重策略（先确保可行，后追求优解）。在结果环节，以收益曲线与结构堆叠图建立评价闭环，为后续鲁棒与滚动策略提供对照与校准依据。



0.4 不确定性与保底收益（问题二）

0.4.1 背景与建模框架

0.4.1.1 问题背景与建模思路

在实际农业生产中，单产、价格、成本与销量上限受气候、市场、政策等因素影响，存在显著的年际与季节波动。仅依据“名义参数”进行确定性规划，当面临不利情形时，方案可能失效，导致超产滞销、收益大幅下滑等风险。本章基于问题一的约束结构与业务规则，引入鲁棒优化理论框架，构建面向“保底收益”的决策模型：在所有允许的参数扰动范围内，确保方案始终可行，并最大化最坏情形下的净收益下界。

在建模方法上，本章以业务逻辑定义不确定集合，采用对偶理论与标准化模板构建鲁棒等价模型，并通过可视化对比分析确定性方案与鲁棒方案的性能差异，突出方案的实施可行性与风险稳健性。

1 本章贡献与创新点

本章的贡献与创新点包括：**可解释的不确定集口径**——提出盒式与预算不确定集的工程化标定与分组口径，使参数 Γ 与业务风险承受度直连，并给出“相关性成组—预算约束”的口径映射；**可解的鲁棒等价模板**——在问题一可行域基础上，给出 Bertsimas-Sim 体例的线性鲁棒重构与对偶化要点，规模线性增长、分钟级可解；**可复现的评测与选点流程**——构建名义/最坏/蒙特卡洛三情景评测与前沿选点流程，并配套脚本与图表支持审计与复核。

0.4.1.2 不确定集定义（业务口径）

为兼顾可解释性与可解性，采用两类常见不确定集。记参数向量 $\xi = (p, y, c, u)$ 。

盒式不确定集（区间波动，逐项独立）：

$$\mathcal{U}_{\square} = \{ \xi : \underline{\xi} \leq \xi \leq \bar{\xi} \}. \quad (12)$$

业务含义：每个参数在“历史区间/置信区间”内任意波动。

预算不确定集（成组扰动，控制“同时最坏”的数量）：

$$\mathcal{U}_{\Gamma} = \left\{ \xi = \hat{\xi} + \sum_j \rho_j d^{(j)} : \sum_j |\rho_j| \leq \Gamma, |\rho_j| \leq 1 \right\}. \quad (13)$$

业务含义：最多允许 Γ 个“关键参数分量”同时取近最坏值，其他分量仅小幅波动。 Γ 越大越保守。

1 数据映射与口径

将题目数据口径映射到不确定集： p 为作物分时价格， y 为分地块/分季单产， c 包含种植、管理等单位成本， u 为销量上限。区间上下界可由“历史均值 $\pm$ 倍数标准差”或“题目给定范围”给出；预算不确定集中的分量可按“作物-季-地块”或“作物-季”成组， Γ 代表“同一季内同时遭遇不利扰动的维度数”。

2 盒式不确定集的特例

当采用区间集 $\mathcal{U}_{\square}$ 时，每个分量独立达到最不利值，鲁棒等价可退化为“名义值减去最大负向偏差”的闭式表达。以单产与销量上限为例：

$$q_{tsk} \leq \sum_i (\bar{y}_{tsk} - \sigma_{tsk}) x_{tsik}, \quad q_{tsk} \leq \bar{u}_{tsk} - \delta_{tsk}^{\max}, \quad (14)$$

其中 $\sigma_{tsk} \geq 0$ 、 $\delta_{tsk}^{\max} \geq 0$ 分别为单产与销量上限在盒式集下的最大负向偏差幅度。该特例计算简洁、口径直观，但较预算集更保守。

0.4.2 鲁棒目标与等价重构

为突出“保底收益”，我们采用“最坏情形净收益最大化”思想。令 r_t^{rob} 表示在不确定集内经由约束重构后的年度净收益，则总体目标可表述为

$$\max \sum_{t \in \mathcal{T}} r_t^{\text{rob}} \quad \text{s.t. 所有鲁棒化约束成立于 } \xi \in \mathcal{U}. \quad (15)$$

直觉上，这等价于“先看最坏、再求最优”：无论参数如何在 $\mathcal{U}$ 里波动，方案都可行且年度收益的下界尽量高。

1 销量上限的鲁棒化（示例）

基式 $q_{tsk} \leq u_{tsk}$ ，若 $u_{tsk} \in [\underline{u}_{tsk}, \bar{u}_{tsk}]$ 且采用预算不确定集，则其鲁棒等价可写为：

$$q_{tsk} \leq \bar{u}_{tsk} - \Gamma_{tsk}^{(u)} \eta_{tsk} - \sum_{j \in \mathcal{J}_{tsk}} \zeta_{tsk}^{(j)}, \quad \forall t, s, k, \quad (16)$$

$$\zeta_{tsk}^{(j)} \geq \delta_{tsk}^{(j)} - \eta_{tsk}, \quad \zeta_{tsk}^{(j)} \geq 0, \quad \eta_{tsk} \geq 0, \quad \forall j, \quad (17)$$

其中 $\delta_{tsk}^{(j)}$ 为销量上限的最大负向偏差分量。直觉：右端做了“保守折减”，防止“超产卖不出”。

2 代表性鲁棒重构示例（预算不确定集，Bertsimas-Sim^[3] 体例）

以“产销匹配”约束为例（与问题一一致的语义）：

$$q_{tsk} \leq \sum_i y_{tsk} x_{tsik} \quad \forall t, s, k. \quad (18)$$

若单产 y_{tsk} 在区间内波动且采用预算不确定集（13），其鲁棒等价的一种标准线性化写法为（给出精简版模板，业务可读）：

$$q_{tsk} \leq \sum_i \bar{y}_{tsk} x_{tsik} - \Gamma_{tsk} \theta_{tsk} - \sum_i \pi_{tsik}, \quad \forall t, s, k, \quad (19)$$

$$\pi_{tsik} \geq \sigma_{tsk} x_{tsik} - \theta_{tsk}, \quad \pi_{tsik} \geq 0, \quad \theta_{tsk} \geq 0, \quad \forall t, s, i, k. \quad (20)$$

其中 $\bar{y}_{tsk}$ 为名义单产， σ_{tsk} 为单产的最大负向偏差幅度， Γ_{tsk} 控制“同时最坏”的地块数/影响量。直观理解：右端做了“安全折减”，折减量由 Γ 与单产不利偏差驱动。类似地，若销量上限 u_{tsk} 存在区间不确定，其约束 $q_{tsk} \leq u_{tsk}$ 也可按同一模板进行鲁棒化（此处不再重复公式）。

3 推导要点（对偶化模板）

Bertsimas-Sim 框架可将“预算不确定集下的最坏情形”通过线性对偶化转为等价的确定性线性约束。以产销匹配为例，

$$q_{tsk} \leq \sum_i y_{tsk} x_{tsik} \quad \forall y \in \mathcal{U}_\Gamma \quad (21)$$

$$\Leftrightarrow q_{tsk} \leq \sum_i \bar{y}_{tsk} x_{tsik} - \Gamma_{tsk} \theta_{tsk} - \sum_i \pi_{tsik}, \quad (22)$$

$$\pi_{tsik} \geq \sigma_{tsk} x_{tsik} - \theta_{tsk}, \quad \pi_{tsik} \geq 0, \quad \theta_{tsk} \geq 0. \quad (23)$$

本质是将“至多 Γ 个分量同时最坏”的非凸组合通过对偶影子价 θ, π 线性刻画出来，既可解又便于业务解释。

4 一般化鲁棒模板小结（Bertsimas-Sim）

记一般线性约束 $\sum_j \tilde{a}_j x_j \leq b$ ，其中不确定系数 $\tilde{a}_j \in [\bar{a}_j - \sigma_j, \bar{a}_j + \sigma_j]$ ，并施加预算约束 $\sum_j |\rho_j| \leq \Gamma$ ， $\tilde{a}_j = \bar{a}_j + \rho_j \sigma_j$ 。其鲁棒等价

$$\sum_j \bar{a}_j x_j \leq b - \Gamma \theta - \sum_j \pi_j, \quad (24)$$

$$\pi_j \geq \sigma_j |x_j| - \theta, \quad \pi_j \geq 0, \theta \geq 0. \quad (25)$$

直观地看，右端“名义上界 b ”被 Γ 与最不利偏差驱动的项折减，从而给予可行性的安全裕度。若是“ $\geq$ ”型约束或不确定在右端，可做对称处理，口径一致。

5 右端不确定与“ $\geq$ ”型约束的处理

若约束为 $\sum_j a_j x_j \geq \tilde{b}$ 且 $\tilde{b} \in [\bar{b} - \sigma_b, \bar{b} + \sigma_b]$ ，其“最坏情形”会使右端变小。采用预算集并对偶化，可得等价形式

$$\sum_j a_j x_j \geq \bar{b} + \Gamma \vartheta + \sum_q \varpi_q, \quad (26)$$

$$\varpi_q \geq -\delta_q - \vartheta, \quad \varpi_q \geq 0, \vartheta \geq 0, \quad (27)$$

其中 $\delta_q \geq 0$ 为右端偏差分量；与“ $\leq$ ”型相对，号向相反（因右端朝不利方向减小）。若右端系多个不确定分量的线性组合，可按分量求和后共享一组 ϑ, ϖ 模板处理。

命题 0.1 (Bertsimas - Sim 等价 (简述)): 对线性约束 $\sum_j \tilde{a}_j x_j \leq b$ ，若 $\tilde{a}_j \in [\bar{a}_j - \sigma_j, \bar{a}_j + \sigma_j]$ 且满足预算约束 $\sum_j |\rho_j| \leq \Gamma$ ，则其鲁棒对应问题等价于 (24) – (25) 的线性约束组。

证明要点 将内层“最坏偏差选择”写成对 ρ 的线性规划，其目标为最大化 $\sum_j (\pm \sigma_j |x_j|) \rho_j$ 且受 ℓ_1 预算与 $|\rho_j| \leq 1$ 限制；其对偶即引入 θ, π 的背包类对偶，强对偶成立给出等价确定性线性化。 $\geq$ 型与右端不确定同理可得带正向折增项的模板。 ■

6 成本与价格的不确定性

- 价格偏低会压缩收入项 $\sum p_{tsk} q_{tsk}$ ；成本偏高会放大利润扣减项 $\sum c_{tsk} x_{tsik}$ 。在盒式或预算集下，二者的“最坏组合”通过目标或对偶变量自然体现。工程实现中，我们统一在目标的“可得收入—必要成本—切换成本”框架内嵌入上述保守化项，与问题一的式（净收益分解）保持口径一致。为示意其等价线性化写法，给出价格/成本在预算集下的一种模板：

$$r_t^{\text{rob}} = \min_{p \in \mathcal{U}_\Gamma^{(p)}, c \in \mathcal{U}_\Gamma^{(c)}} \left\{ \sum_{s,k} p_{tsk} q_{tsk} - \sum_{s,i,k} c_{tsk} x_{tsik} \right\} \quad (28)$$

$$\begin{aligned} &\geq \sum_{s,k} \bar{p}_{tsk} q_{tsk} - \Gamma_t^{(p)} \theta_t^{(p)}, \\ &\quad - \sum_{s,k} \pi_{tsk}^{(p)} - \sum_{s,i,k} \bar{c}_{tsk} x_{tsik} \end{aligned} \quad (29)$$

$$\begin{aligned}
& -\Gamma_t^{(c)} \theta_t^{(c)} - \sum_{s,i,k} \pi_{tsik}^{(c)}, \\
& \pi_{tsk}^{(p)} \geq \sigma_{tsk}^{(p)} q_{tsk} - \theta_t^{(p)}, \quad \pi_{tsik}^{(c)} \geq \sigma_{tsk}^{(c)} x_{tsik} - \theta_t^{(c)}, \quad \pi, \theta \geq 0. \quad (30)
\end{aligned}$$

其中 $\sigma^{(p)}, \sigma^{(c)}$ 为价格与成本的负向偏差幅度。盒式集作为特例可令 Γ 取到最大并省去 θ, π 的联动项，直接做按分量的“最坏折减”。

0.4.3 约束体系与求解流程

为避免重复，这里仅给出与问题一的关键差异。基础可行域（地块面积、同季不重叠、适宜性、产销匹配、资源约束、轮作/重茬与切换成本）沿用不变；凡右端依赖 y, p, u 的关键约束，均以“名义值减去保守折减”的形式替换为鲁棒等价，并通过 Γ 调节“稳健度—收益”的权衡。目标保持为“在所有允许扰动下净收益下界最大”，与业务对“更稳的保底收益”的诉求一致。

1 复杂度与求解建议

为每条被鲁棒化的约束引入 θ, π 等辅助变量后，规模按“约束数 + 变量数”线性增长，分钟级可解性保持。工程上宜启用求解器预处理与削弱（presolve、probing），并在资源与切换约束上打开隐式 SOS 识别；以 $\Gamma = 0$ 的解作为热启动，逐步提升 Γ ，必要时设置松弛上界与迭代时间窗；同时设置 MIPGap 与 TimeLimit，并记录各 Γ 的最优值与可行解，以便绘制前沿并支撑选点。

0.4.3.1 求解流程与可解性（工程实现）

我们沿用问题一的求解器与工程套路，仅新增少量辅助变量（如 θ, π ）。实践中，变量与约束规模相对问题一仅线性增加，分钟级可解性保持不变；稳健度调参采用 $\Gamma \in \{0, 1, 2, \dots\}$ 的网格， $\Gamma = 0$ 退化为确定性基线， Γ 增大时保底收益抬升但可能让渡部分乐观收益；工程上先解 $\Gamma = 0$ 作为热启动，随后逐步增加 Γ ，必要时采用分块或割的增量注入。

0.4.3.2 可调鲁棒与分布鲁棒的取舍（说明）

可调鲁棒（ARC）^[4] 允许部分决策在观测后调整，求解为分段线性但规模更大；分布鲁棒（DRO）^[5] 在“分布集合”上最坏化，能显式控制覆盖概率与尾部风险。鉴于题目规模与实施成本，本章取“静态鲁棒 + 预算集”兼顾可解性与业务可解释性，将 ARC/DRO 作为展望方向（见本章小结）。

0.4.4 实验设计与评测指标

为评估鲁棒方案的稳健性，我们构建三类评测情景：名义情景以历史均值或题面给定的基准值设定 p, y, c, u ；最坏情景近似在预算不确定集下按 Bertsimas-Sim 体例优先激活负向偏差，模拟“同季多维同时不利”的边界情况；蒙特卡洛情景在区间内抽样生成 $N = 500$ 个样本，从分布视角评估尾部风险与稳定性（后悔值、违约率等）。情景参数的上下界与偏差幅度来自题设数据与历史波动口径，抽样采用拉丁超立方或分层抽样以保证覆盖率。所有方案均在相同情景集上评测以确保可比性。

1 指标与估计量的形式化定义

令 x^Γ 表示在稳健度 Γ 下得到的最优结构。定义

$$r^{\min}(\Gamma) = \min_{\xi \in \mathcal{U}_\Gamma} \sum_t r_t(x^\Gamma, \xi), \quad r^{\text{nom}}(\Gamma) = \sum_t r_t(x^\Gamma, \hat{\xi}), \quad (31)$$

并给出蒙特卡洛均值估计量（用于考察均值让渡）：

$$\hat{r}^{\text{avg}}(\Gamma) = \frac{1}{N} \sum_{n=1}^N r(x^\Gamma, \xi^{(n)}), \quad (32)$$

其中 $\xi^{(n)}$ 为在区间内按既定方案抽样得到的情景。上述三个量共同刻画“保底—均值—尾部”的权衡。

2 样本量与功效（简析）

若希望对 $\hat{r}^{\text{avg}}(\Gamma)$ 给出半宽不超过 ε 的 95% 置信区间，则近似需

$$N \gtrsim \left(\frac{1.96 s(\Gamma)}{\varepsilon} \right)^2, \quad (33)$$

其中 $s(\Gamma)$ 可由小样本预估。若比较两种结构的均值差 Δ ，功效 $1 - \beta$ 下的样本量近似按双样本 t 检验口径确定（此处略），实际取值可在 $N \in [300, 800]$ 之间权衡计算成本与精度。

0.4.4.1 参数边界与 σ 标定方法

为保证不确定集口径可复核、可解释，我们采用一段式叙述：选择近 $L \in [3, 5]$ 年作为窗口，并按“作物一季（必要时含地块）”分组得到样本集 $\mathcal{W}_{tsk}$ ；以分位数给出区间（如 $[Q_\alpha, Q_{1-\alpha}]$ ，或先对原样本 Winsorize 后取上下界）；偏差幅度 σ 可取标准差 $\sigma_{tsk} = \text{sd}(\mathcal{W}_{tsk})$ 或稳健尺度 $\sigma_{tsk} = 1.4826 \text{MAD}(\mathcal{W}_{tsk})$ 。预算集中的分量按“作物一季（或地块）”成组， Γ 的含义与分组一致；最后在历史滚动窗口上回测

违约率与最坏收益下界，微调 α, σ, Γ 以满足“保底 $\geq$ 阈值、违约 $\leq$ 阈值”的要求。

0.4.4.2 抽样设计与置信区间

为衡量均值与尾部不确定性，给出标准误与置信区间口径。设样本均值与样本标准差分别为

$$\bar{r}(\Gamma) = \frac{1}{N} \sum_{n=1}^N r(x^\Gamma, \xi^{(n)}), \quad s(\Gamma) = \sqrt{\frac{1}{N-1} \sum_{n=1}^N (r(x^\Gamma, \xi^{(n)}) - \bar{r}(\Gamma))^2}. \quad (34)$$

在大样本下，95% 置信区间近似为 $\bar{r} \pm 1.96 s / \sqrt{N}$ 。若关注后悔值的分位点，可用百分位自助法（bootstrap）估计其置信带，不改变正文图表，仅作为复核材料。

0.4.5 参数标定与 Gamma 选择

Γ 表示“同一季内最多有多少个维度同时处于近最坏状态”。选点遵循“收益—稳定性”双指标：以最坏情景下的净收益下界衡量保底水平，同时关注名义或均值情景下的净收益以避免过度保守带来的机会损失。图10(a) 展示了 Γ -收益的前沿曲线，文中推荐点兼顾下界与均值；企业可依据执行能力与市场波动容忍度微调 Γ 。


1 选点流程（工程化指引）

在实际使用中，可按“求解—阈值过滤—帕累托选择”的三步走执行：先在网格 $\Gamma \in \{0, 1, 2, \dots\}$ 上求解并缓存 x^Γ 与评测指标（ $r^{\min}$ 、 r^{nom} 、 $\hat{r}^{\text{avg}}$ 、ViolRate、AvgGap）；随后依据业务阈值“保底 $\geq X$ 、违约 $\leq Y\%$ ”过滤候选；若多解并列，优先选择切换更少、峰值资源更低者。

2 算法伪代码： Γ 网格—帕累托过滤

算法 0.1 Γ -Grid 与帕累托过滤

- 1: 输入：网格 $\mathcal{G}$ ，阈值 $(X, Y\%)$ ；输出：推荐 Γ^*
 - 2: **for** $\Gamma \in \mathcal{G}$ **do**
 - 3: 求解鲁棒模型得 x^Γ ，计算 $r^{\min}, r^{\text{nom}}, \hat{r}^{\text{avg}}, \text{ViolRate}, \text{AvgGap}$
 - 4: **end for**
 - 5: 候选集 $S \leftarrow \{\Gamma : r^{\min} \geq X, \text{ViolRate} \leq Y\%\}$
 - 6: 在 S 内做帕累托过滤：支配准则为“ $r^{\min}$ 高、切换少、峰值资源低、 r^{nom} 不低于阈值”
 - 7: 返回 Γ^* ：若多解并列，选切换更少者
-

图 8 参数标定流程（ Γ -Grid 与帕累托过滤）

3 Γ 的边际分析与停增准则

设离散边际提升与机会成本为

$$\Delta r^{\min}(\Gamma) = r^{\min}(\Gamma) - r^{\min}(\Gamma - 1), \quad \Delta r^{\text{nom}}(\Gamma) = r^{\text{nom}}(\Gamma - 1) - r^{\text{nom}}(\Gamma). \quad (35)$$

常见停增规则包括：

- **阈值法**：取最小的 Γ 使得 $r^{\min}(\Gamma) \geq X$ 且 $\text{ViolRate}(\Gamma) \leq Y\%$ ；
- **性价比法**：当边际收益比 $\Delta r^{\min}(\Gamma) / \max\{\Delta r^{\text{nom}}(\Gamma), \varepsilon\}$ 低于预设阈值时停止增加 Γ ；
- **平滑性优先**：当多个 Γ 值并列时，选择切换频次更少、峰值资源占用更低的方案。

4 分层 Γ 设定（按季/品种）

工程上， Γ 可分层设定以贴合风险不均衡：在高波动季（如雨季）可取更大的季节层级 $\Gamma_{t,s}$ ，对价格/单产波动更大的品种可取更大的品种层级 $\Gamma_{t,k}$ ；并通过上界约束控制 $\sum_{s,k} \Gamma_{t,sk} \leq \Gamma_t^{\max}$ 以避免过度保守。分层方式需与不确定分组一致（如按“作物一季”建组），以保持对偶模板口径不变。

5 与机会约束的关系（保守外逼近）

若目标是满足机会约束 $\mathbb{P}\{g(x, \xi) \leq 0\} \geq 1 - \alpha$ ，直接求解在计算上较为困难。在对称区间分布与预算约束下，Bertsimas-Sim 不确定集 $\mathcal{U}_\Gamma$ 可视为对该机会约束的保守外逼近：

$$\{g(x, \xi) \leq 0, \forall \xi \in \mathcal{U}_\Gamma\} \Rightarrow \mathbb{P}\{g(x, \xi) \leq 0\} \geq 1 - \alpha, \quad (36)$$

其中 α 与 Γ 的数值关系依赖数据分布与分组方式，实务中可通过历史回测对 (α, Γ) 做经验校准。本章采用鲁棒外逼近以保障可解性与可解释性。

6 鲁棒化模板总表（汇总）

为便于工程复用，给出三类常用模板。以下均假设 $x \geq 0$ （若存在自由变量，可作差分解或引入正负部）：**系数不确定、 $\leq$ 约束**： $\sum_i (\bar{a}_i + \hat{a}_i z_i) x_i \leq b$, $\sum z_i \leq \Gamma$, $z \in [0, 1]$ 。鲁棒等价如下：

$$\sum_i \bar{a}_i x_i + \Gamma \theta + \sum_i \pi_i \leq b, \quad (37)$$

$$\pi_i \geq \hat{a}_i x_i - \theta, \pi_i \geq 0, \theta \geq 0.$$

右端不确定、 $\leq$ 约束： $\sum_i \bar{a}_i x_i \leq \bar{b} - \sum_j \hat{b}_j z_j$, $\sum z_j \leq \Gamma$ 。等价形式为：

$$\sum_i \bar{a}_i x_i + \Gamma \theta + \sum_j \pi_j \leq \bar{b}, \quad (38)$$

$$\pi_j \geq \hat{b}_j - \theta, \pi_j \geq 0, \theta \geq 0.$$

系数不确定、 $\geq$ 约束： $\sum_i (\bar{a}_i - \hat{a}_i z_i) x_i \geq c$, $\sum z_i \leq \Gamma$ （最坏情形降低左端）。对应鲁棒等价：

$$\sum_i \bar{a}_i x_i - \Gamma \theta - \sum_i \pi_i \geq c, \quad (39)$$

$$\pi_i \geq \hat{a}_i x_i - \theta, \pi_i \geq 0, \theta \geq 0.$$

7 规模与复杂度估计

设某条基准约束含 m 个不确定分量，则鲁棒化后新增变量 $1 + m$ （ θ 与 π ），新增不等式 m 。整体规模按“基准约束数 $\times$ 其不确定分量数”线性增长，仍为 LP。若变量含正负号，可将 x 拆成 $x^+ - x^-$ 并按上表套用。

8 等价命题要点补充 (Bertsimas-Sim)

核心在于将“在 $\sum z \leq \Gamma$ 下最大化不利偏差之和”的 0-1 组合问题以对偶化转写为线性形式：

$$\max_{0 \leq z \leq 1, \sum z \leq \Gamma} \sum_i w_i z_i = \min_{\theta \geq 0, \pi \geq 0} \left\{ \Gamma \theta + \sum_i \pi_i : \pi_i \geq w_i - \theta \right\}. \quad (40)$$

将 w_i 取为相应的“系数偏差 $\times$ 决策量”或“右端缩减幅度”，代入原约束即可得到上述模板。若 Γ 为整数，该等价由全 unimodularity 支撑；非整数 Γ 时出现至多一个分量的分数选择，对偶同样捕捉到该“临界”效应。

0.4.6 数值结果与业务解读

0.4.6.1 业务解读与管理启示

鲁棒优化并非追求“处处最优”，而是在可接受的保守度下规避极端不利情形。实验显示：在高风险季或波动较大的品种上适度降配，可使结构更稳、跨季大幅切换减少；对销量上限与单产的保守折减使库存与销量更匹配，显著降低“超产卖不出”的尾部风险；同时针对关键资源配额预设“阈值触发的备选结构”，将不确定性前置到方案设计阶段。

0.4.6.2 数值实验与结果解读

我们对比“确定性 vs. 鲁棒”的收益曲线与结构变化，并给出多维图示。总体上，鲁棒方案的最坏收益显著抬升且波动收敛；确定性方案在名义情景下均值略高但尾部更弱。随 Γ 增大，保底收益上升而名义收益小幅让渡，形成可解释的前沿曲线（见图 10(a)）。结构上，鲁棒方案在“高不确定季”的配置更克制，切换次数与跨季跳变减少（见图 12）。下列图均由自动化流程生成，口径与问题一一致；抽样固定随机种子以保证复现，整体可复现可审计。

0.4.6.3 复现实验指引

环境与依赖：建议 Python ≥ 3.9 。常用依赖包含 numpy、pandas、matplotlib（或 seaborn），统计检验可选 scipy（复现实验环境已统一配置，具体操作细节不在正文展开）。**随机性与种子：**实现中先固定随机种子（如设置 SEED 或调用 `numpy.random.seed`），再进行抽样或情景生成，以确保图表可重复。**审计与复核：**核对生成文件的时间戳与尺寸，并对比论文中的图编号与标题。若存在差异，优先确认脚本参数（特别是 Γ 网格与样本量 N ）与数据口径是否一致。

1 图表—脚本映射（可复现）

为便于审计复核，Model 2 的图均由下列脚本自动生成。图内标签（如 `\label{fig:model2-revenue-curve}`）均已在正文中定义、保持不变。

图文件（figures/）	生成脚本（python/figures_model2/）
model2_revenue_curve.pdf	model2_revenue_curve.py
model2_regret_curve.pdf	model2_regret_curve.py
model2_gamma_frontier.pdf	model2_gamma_frontier.py
model2_structure_stack_area_gamma.pdf	model2_structure_stack_area_gamma.py
model2_violation_risk_bar.pdf	model2_violation_risk_bar.py
model2_resource_util_line_robust.pdf	model2_resource_util_line_robust.py
model2_switch_heatmap_robust.pdf	model2_switch_heatmap_robust.py
model2_sensitivity_spider_robust.pdf	model2_sensitivity_spider_robust.py

表 4 Model 2 图表与生成脚本的对应关系（标签保持不变）

2 统计显著性与稳健性检验

为避免“肉眼评图”的主观性，我们对关键结论进行统计复核：

均值比较：在相同情景集下比较两方案的年度收益均值，采用双样本 t 检验（或配对 t 检验，视抽样设计而定），并报告效应量 Cohen's d 。在非正态或重尾分布下，以置换检验作为稳健替代。

分布差异检验：对“后悔值”和“最坏分位收益”（如 5% 分位）使用百分位自助法（bootstrap）构造 95% 置信区间，并用 Kolmogorov-Smirnov 检验或能量距离检验复核分布差异。

违约率分析：对违约率（ViolRate）进行比例差异的 z 检验或 Fisher 精确检验，并报告绝对差与相对差的区间估计，避免仅依赖 p 值进行判断。

3 多重比较校正（避免第一类错误膨胀）

在同时比较多个指标或多个 T 时，建议进行多重校正：控制家族错误率（FWER）可用 Bonferroni 或 Holm-Bonferroni，当指标较多时控制发现率（FDR）可用 Benjamini-Hochberg（BH）。具体而言，Bonferroni 将显著性阈值改为 α/m （ m 为同时检验数），稳健但偏保守；Holm-Bonferroni（推荐于 $m \leq 5$ ）按升序排列 $p_{(k)}$ ，依次比较 $p_{(k)} \leq \alpha/(m - k + 1)$ 并在首次不通过时停止；BH-FDR（推荐于 $m > 5$ ）给定 FDR 目标 q （如 $q = 0.10$ ），取最大 k 使 $p_{(k)} \leq (k/m)q$ ，从而拒绝 $1 \dots k$ 个原假

设。报告时应给出校正后的 p_{adj} 或注明所用方法与 α/q ，并在附录列出指标清单与 m 的确定口径。以上检验均在相同的抽样情景上进行，避免“基准不一致”带来的比较偏差。

4 收益差异的要素分解

为解释“鲁棒为何提升保底且让渡少量名义收益”，将收益差异拆解为收入、成本与切换三部分：

$$\begin{aligned}
 \Delta r = & \underbrace{\left[\sum_{t,s,k} p_{tsk} q_{tsk} \right]_{\text{rob}} - \left[\sum_{t,s,k} p_{tsk} q_{tsk} \right]_{\text{det}}}_{\Delta \text{Revenue}} \\
 & - \underbrace{\left[\sum_{t,s,i,k} c_{tsk} x_{tsik} \right]_{\text{rob}} - \left[\sum_{t,s,i,k} c_{tsk} x_{tsik} \right]_{\text{det}}}_{\Delta \text{Cost}} \\
 & - \underbrace{\left[\sum_{t,s,i,k} \kappa_{sik} \Delta z_{tsik} \right]_{\text{rob}} - [\cdot]_{\text{det}}}_{\Delta \text{Switch}}.
 \end{aligned} \tag{41}$$


实务中可进一步做“因素归因”：沿一条从确定性到鲁棒的路径逐步注入“右端折减/价格成本保守化/切换惩罚调整”，以路径平均（Shapley 风格）方式度量每一因素对 Δr 的贡献，便于定位收益变化的主要来源并指导改进。

5 消融一：盒式 vs. 预算不确定集

在相同“平均偏差幅度”下，盒式集相当于 Γ 取满，因而更保守；预算集通过 Γ 限制“同时最坏”的维度数，形成更灵活的保底—均值权衡。经验上，盒式的违约率最低但让渡更大，预算集在同等保底目标下可获得更高的名义与均值收益。

6 消融二：无切换成本 vs. 有切换成本

在鲁棒化同时移除切换成本会导致跨季结构更激进，尽管保底收益得到保障，但执行路径不稳、资源峰值偏高；加入切换成本后，极端跳变被抑制，与鲁棒右端折减形成互补，整体风险—执行性的折中更佳。



(a) 年度收益曲线：确定性 vs. 鲁棒（问题二）。鲁棒方案显著抬升最坏情形的收益下界，年际波动更小；确定性方案在名义情景下略高，但尾部更弱。

(b) 后悔值 ECDF 对比。鲁棒方案的后悔值分布整体左移、尾部概率显著降低，体现“抗尾部”的稳健性。

图9 收益与风险概览：年度收益曲线与后悔值 ECDF 对比

7 图9(a) 解读

鲁棒目标可写成“最坏情形净收益最大化”的极大极小问题：

$$\max_{x,z,q} \min_{\xi \in \mathcal{U}} \sum_{t \in \mathcal{T}} \left(\underbrace{\sum_{s,k} p_{tsk}(\xi) q_{tsk}}_{\text{收入}} - \underbrace{\sum_{s,i,k} c_{tsk}(\xi) x_{tsik}}_{\text{成本}} - \underbrace{\sum_{s,i,k} \kappa_{sik} \Delta z_{tsik}}_{\text{切换成本}} \right) \quad (42)$$

其中 $\mathcal{U}$ 为不确定集， Δz_{tsik} 根据相邻季的作物选择定义切换指示变量。对于盒式不确定集 $\mathcal{U}_{\square}$ 或预算不确定集 $\mathcal{U}_T$ ，上述极大极小问题（42）中的“内层最小化”可通过对偶理论转化为等价的确定性线性约束，从而得到目标函数（15）的可求解形式。图中鲁棒方案收益曲线在尾部的抬升效应，正是约束右端“保守折减”项发挥作用的直接体现。




图 10 Γ 影响下的收益前沿与结构形态对比

8 鲁棒预算 Γ 的定量权衡


Γ 控制“同时最坏”的维度数。以单产鲁棒化式 (19) – (20) 为例，当 Γ 增大时，安全折减项 $\Gamma \theta_{tsk} + \sum_i \pi_{tsik}$ 增大，约束收紧，导致“保底收益”抬升、名义收益让渡。可用如下双指标择优：

$$\text{maximize } r^{\min}(\Gamma) \quad \text{s.t. } r^{\text{nom}}(\Gamma) \geq r_{\min}^{\text{nom}}, \quad (43)$$

其中 $r^{\min}$ 为最坏情形下界， r^{nom} 为名义情景收益。图 10(a) 的推荐点即为 (43) 的可行帕累托点之一。

9 结构变化的机制

鲁棒化相当于对“产销匹配”与“销量上限”等关键约束的右端做折减（见式 (18) 与其鲁棒等价），加之切换成本项（问题一的式 (10)），共同抑制“激进跳变”。因此在高不确定季/品种上，面积配置更克制，跨季跃迁减少。



(a) 约束违约风险对比：确定性 vs. 鲁棒。鲁棒方案在产销匹配、销量上限与关键资源约束上显著降低违约概率与幅度。
(b) 资源利用率跨期对比（鲁棒 vs. 确定性）。鲁棒方案在关键瓶颈期更均衡，峰值占用降低，有助于缓解产能与人力压力。

图 11 稳健性对约束违约与资源占用的影响：违约率与资源利用并排对比

10 违约风险的度量

设情景集 Ω ，定义违约指标 $\mathbb{I}_{\text{viol}}(\omega)$ 表示在情景 $\omega \in \Omega$ 下任一关键约束被违反。违约率与平均违约幅度可写为

$$\text{ViolRate} = \frac{1}{|\Omega|} \sum_{\omega \in \Omega} \mathbb{I}_{\text{viol}}(\omega), \quad \text{AvgGap} = \frac{1}{|\Omega|} \sum_{\omega \in \Omega} \frac{1}{|C|} \sum_{c \in C} [g_c(\omega)]_+, \quad (44)$$

其中 $g_c(\omega)$ 为约束 c 的违反量， $[\cdot]_+$ 为正部算子。鲁棒化通过“右端折减 + 预算保护”显著降低二者。

11 后悔值与 ECDF

定义在情景 ω 下的后悔值 $\text{Reg}(\omega) = r^*(\omega) - r(\omega)$ ，其中 r^* 为“事后最优”（不可达）基准。经验分布函数 $\text{ECDF}(x) = \frac{1}{|\Omega|} \sum_{\omega} \mathbb{I}\{\text{Reg}(\omega) \leq x\}$ ，鲁棒方案使 ECDF 明显左移，尾部小概率大后悔事件显著压缩。

12 资源瓶颈的缓解

资源约束（问题一式（9））在旺季可能成为主瓶颈。鲁棒化对 y, p, u 的保守折减使排产更均衡，从而降低峰值占用，替代“事后救火”的加班或弃收。




图 12 鲁棒方案切换频次热力图。跨季/跨作物的跳变明显减少，执行路径更平滑，切换成本与不确定性暴露同步下降。

13 切换频次的形式化定义

令 $z_{tsik} \in \{0, 1\}$ 表示是否在季 s 于地块 i 种植作物 k ，定义相邻季的切换指标 $\sigma_{t,s,i} = \frac{1}{2} \sum_k |z_{t,s+1,i,k} - z_{t,s,i,k}|$ 。总切换成本 $\sum_{t,s,i} \kappa_{sik} \sigma_{t,s,i}$ 与执行复杂度正相关，鲁棒化通过结构更稳来降低该项。




图 13 关键因素对收益波动的敏感性（鲁棒 vs. 确定性）。两方案对主要因素的影响排序基本一致，但鲁棒方案对负向扰动的灵敏度更低。

14 敏感性口径

取因素集合 Φ 与微扰幅度 $\delta > 0$ ，定义对因素 $\phi \in \Phi$ 的一阶敏感性

$$S(\phi) = \frac{r(\hat{\xi} + \delta e_{\phi}) - r(\hat{\xi} - \delta e_{\phi})}{2\delta}, \quad (45)$$

其中 e_{ϕ} 为在分量 ϕ 处为 1 的基向量。鲁棒方案的 $|S(\phi)|$ 普遍更小，表明对负向扰动更不敏感。

0.4.7 实施建议与复核

0.4.7.1 答案与输出（落地口径）

为便于评审与执行，输出包括：地块一季一作物排产表（在鲁棒参数下的面积与是否种植，标注 x^*, z^* ），作物产销与收益表（在名义、最坏及随机抽样多情景下的产量、销量与收益，含 q^* 与 r_i^{rob} ），以及资源利用率与切换统计，辅助复核可实施性。

附表清单

符号	含义（业务口径）	维度/类型	备注
Γ	鲁棒预算参数，控制“同时最坏”的维度数	$\mathbb{Z}_{\geq 0}$	调节稳健度—收益权衡
$\mathcal{U}_{\square}$	盒式不确定集（区间波动）	集合	见式（12）
$\mathcal{U}_{\Gamma}$	预算不确定集（ ℓ_1 预算）	集合	见式（13）
θ_{tsk}	单产鲁棒等价的枢轴变量	≥ 0	见式（19）—（20）
π_{tsik}	单产偏差的辅助折减量	≥ 0	同上
η_{tsk}	销量上限鲁棒等价的枢轴变量	≥ 0	见式（16）—（17）
$\varsigma_{tsk}^{(j)}$	销量偏差分量的辅助变量	≥ 0	同上
$\bar{y}_{tsk}$	名义单产	实数	来源：历史或题设
σ_{tsk}	单产最大负向偏差幅度	非负实数	历史波动标定
$\delta_{tsk}^{(j)}$	销量上限的最大负向偏差分量	非负实数	分量级参数
x_{tsik}	地块一季一作物的种植面积	≥ 0	与问题一口径一致
z_{tsik}	是否种植的 0-1 变量	$\{0, 1\}$	与问题一口径一致
q_{tsk}	销量变量	≥ 0	—
r_t^{rob}	鲁棒年度净收益	实数	见目标（15）

表 5 本章新增符号与口径对照表

0.4.7.2 符号与参数对照表

0.4.7.3 Γ 选点操作化指引

为便于执行，选点流程概述如下：先以 $\Gamma = 0$ （确定性）求解作为基线，获得收益与风险参照；随后取 $\Gamma \in \{1, 2, 3, \dots\}$ 逐点求解并绘制前沿曲线（见图 10(a)），观察“保底抬升—均值让渡”的权衡；最后按业务阈值“保底 $\geq X$ 、违约 $\leq Y\%$ ”筛选推荐点，若存在并列解，优先选择切换更少者。

保底收益阈值	违约率阈值	建议 Γ
$\geq X$	$\leq Y\%$	基于前沿选点（满足阈值的最小 Γ ）

表 6 阈值指引（示例， X/Y 由业务设定）

0.4.7.4 实施与运维建议

建议按月或季度进行周期性重标定，窗口长度取近 3–5 年，对异常值采用 Winsorize 或稳健回归并记录口径变更；线上监控最坏收益（保底）趋势、各类约束违约率、切换频次与位置，设置阈值与趋势告警并在必要时自动调整 Γ ；数据、脚本与图表统一版本管理，固定随机种子，灰度发布 Γ 与结构调整并保留回滚依据。

1 Γ 自适应运维（控制图思路）

设滚动评测窗口 Ω_{roll} ，每期更新统计量

$$(r^{\min}, \text{ViolRate}, \text{AvgGap}, \text{SwitchFreq}). \quad (46)$$

当两期以上连续触发“保底低于阈值或违约超阈值”告警时，按小步长上调 Γ ；当连续多个周期边际收益让渡明显且违约充足安全时，按小步长下调 Γ 。所有调整需灰度发布并回测验证。

0.4.7.5 数值稳定性与尺度化建议

为减小数值误差与求解不稳定：统一价格、成本与收益的量纲（如以千元计）以避免系数跨越 10^4 量级；对面积与产量做适度缩放，使典型变量量级落在 $[10^{-1}, 10^2]$ ；并在求解器中开启比例缩放（scaling）与数值强调（numeric emphasis）等选项以提升数值稳定性。

0.4.7.6 影子价（对偶）与业务含义

影子价的业务解读如下： θ_{tsk} （单产鲁棒枢轴）衡量“同季/品种在最坏情形下所需的统一安全折减强度”，高 θ 表示该季/品种在不确定下更紧张，宜适度降配高波动品种、增加库存/缓冲面积或在该季限制激进扩张； π_{tsik} （单产偏差的分量折减）刻画“地块-季-作物”的边际折减量，高 π 指向具体脆弱点，宜对高 π 的地块做结构分散或换作更稳健品种； $\eta_{tsk}, \zeta_{tsk}^{(j)}$ （销量上限鲁棒枢轴/分量）反映销售能力在最坏情形下的收紧幅度，高 η 或 ζ 表明“卖得出去”更具不确定，宜提前锁定订单/渠道并优化采收与出货节奏以避免“超产卖不出”； $\theta_t^{(p)}, \pi_{tsk}^{(p)}$ 与 $\theta_t^{(c)}, \pi_{tsik}^{(c)}$ （价格/成本鲁棒模板）对应收益与成本项的保守化强度，高 $\pi^{(p)}$ 指向价格敏感的品种/季，高 $\pi^{(c)}$ 指向成本压力大的地块/工序，宜通过中长期合同降低价差风险，并在高成本敏感环节进行工艺与排班优化；读取与呈现方面，可将上述对偶值随季/品种/地块汇总为“热力矩阵”，与决策量 x, q 并列展示（参见符号表 5 的口径），并用阈值高亮“需要干预的位置”；此外，对偶值受尺度影响，建议以“归一化影子价”（如按名义右端或典型规模标准化）比较，以避免错判。

0.4.7.7 本章小结与展望

本章在问题一的可行域与业务规则之上，构建以盒式与预算不确定集为核心的鲁棒优化框架，给出可工程落地的鲁棒等价与求解流程。通过参数 Γ 系统刻画“保底收益—上侧空间”的权衡，并以收益曲线、结构变化、违约风险与敏感性等多维证据予以验证。

1 局限

主要局限包括：参数区间与偏差口径依赖历史或题设，可能低估极端尾部；采用线性模板与静态 Γ ，尚未显式刻画跨期学习与信息更新；未纳入价格—供给的内生反馈与市场博弈，仍属“给定价格/需求”的视角。

2 展望

后续可：结合数据驱动或分布鲁棒（DRO）与机会约束/风险度量（如 CVaR）；引入可调鲁棒与多阶段鲁棒，刻画“决策—观测—再决策”的动态链条；探索不确定集的自适应分组与 Γ 的自动选点（基于信息准则或业务规则）；并与生产执行系统对接，形成“建议—执行—反馈”的闭环，以真实反馈迭代不确定集与模型参数。

第 1 章 论文主要部分的写法

1.1 价格反馈与动态滚动优化策略

本章聚焦在价格—供给存在相互作用、信息逐年滚动更新的背景下，如何以“年”为阶段实施动态规划：每一年度先利用上一年度的真实产量、售价与销量反馈来更新参数分布，再在面向未来若干情景的基础上进行含下行风险控制的再优化，从而输出下一年度的地块—季节—作物配置。与前两章相比，这里更强调价格弹性与销量上限的双重约束对收益分布尾部的影响，并通过引入 CVaR（条件在险价值）在目标函数中显式惩罚“坏情景”的收益，进而提升保底表现。

为便于理解，我们先以既有结果中的基线收入曲线回顾价格—供给反馈的形状与拐点特征，进而给出动态滚动的建模框架与算法流程；随后展示一组代表性数值实验与敏感性分析，以说明滚动优化在高波动市场中的稳定性优势。




图 1.1 基线收入—供给曲线示意（用于刻画价格弹性与容量上限对总收入的影响）

1.1.1 模型动机与设定

现实市场中，作物的年度均价并非外生常数，供给增加通常压低价格，同时还受到渠道容量与销量上限的约束。基于上一年度的“计划—实际—成交”三元组，我们将价格与销量分别建模为关于“有效供给”的分段线性或光滑可微（如对数线性）的函数族，再辅以不确定项以反映气象、品质与市场情绪带来的扰动。这样得到的价格—供给反馈函数在小供给区近似线性增长，而在接近容量上限时边际收益显著递减，对应到收益曲线便呈现明显的凹性与拐点（见图 1.1）。

为便于后续求解与分析，我们给出两个常用的价格—供给函数原型：

$$\text{线性价格: } p(q) = a - bq, \quad a > 0, b > 0, \quad (1.1)$$

$$\text{对数线性: } \ln p(q) = \ln p_0 - \eta q \Rightarrow p(q) = p_0 e^{-\eta q}, \quad \eta > 0. \quad (1.2)$$

考虑销量上限（或渠道容量） C 与有效销量 $s(q) = \min\{q, C\}$ ，则年度总收入可表述为

$$R(q) = p(q) s(q) = p(q) \min\{q, C\}, \quad (1.3)$$

其一阶导数在 $q = C$ 处出现折点：在 $q < C$ 区间， $\frac{dR}{dq} = p'(q)q + p(q)$ ；在 $q > C$ 区间， $\frac{dR}{dq} = p'(q)C$ 。这正对应图 1.1 的拐点与“容量饱和”现象。若进一步计入单位变动成本 c 与固定成本 F ，则利润为 $\Pi(q) = R(q) - cq - F$ ，在滚动优化中我们以 Π 的分布为核心关切对象。

年度决策向量为“年—季—地块—作物”的面积矩阵 $x_{t,s,i,k}$ ，并配合二进制变量 $z_{t,s,i,k}$ 刻画互斥与重茬约束。标注 $y_{t,s,i,k}$ 为产量， $u_{t,k}$ 为当年售出量，则有效供给 $q_t = \sum_{s,i,k} y_{t,s,i,k}$ ，销量受 $u_t \leq C_t$ 与 $u_t \leq q_t$ 共同约束，价格 p_t 由 q_t 反馈决定。

1.1.1.1 变量与约束总览

核心变量包括： x （面积，连续）、 z （作物-地块-季节是否种植，二进制）、 q （总供给，连续）、 u （销量，连续）、 p （价格，连续）、 r （收入，连续）。关键约束示意：

$$\text{地块面积: } \sum_k x_{t,s,i,k} \leq A_{s,i}, \quad x_{t,s,i,k} \geq 0, \quad (1.4)$$

$$\text{互斥/重茬: } \sum_k z_{t,s,i,k} \leq 1, \quad x_{t,s,i,k} \leq M z_{t,s,i,k}, \quad (1.5)$$

$$\text{产量定义: } y_{t,s,i,k} = \theta_{t,s,i,k} x_{t,s,i,k}, \quad (1.6)$$

$$\text{总供给: } q_t = \sum_{s,i,k} y_{t,s,i,k}, \quad (1.7)$$

$$\text{销量上限: } 0 \leq u_t \leq \min\{q_t, C_t\}, \quad (1.8)$$

$$\text{价格反馈: } p_t = f(q_t; \Theta_t), \quad (1.9)$$

$$\text{收入与利润: } r_t = p_t u_t, \quad \Pi_t = r_t - c^\top x_t - F_t. \quad (1.10)$$

其中 $\theta_{t,s,i,k}$ 可视为不确定单产参数； $f(\cdot)$ 为价格—供给反馈函数，后续采用分段线性近似以进入 MIP。

与设定配套的年度决策向量仍是“年—季—地块—作物”的种植面积变量，二进制变量用于刻画重茬限制与地块—季节的互斥关系。重要差异在于目标函数的

随机性：年度收益取决于当年实现的单产、价格与销量，其联合分布在每年开始时据历史数据和外部信息进行更新，并据此生成未来多情景以供优化。




图 1.2 销量—产能的配比关系示意（容量约束导致的瓶颈区间）

1.1.2 价格—供给—销量反馈与识别

价格函数的识别遵循“解释性—稳定性—可解性”三项权衡：第一，优先采用分段线性或对数线性规格，使其与线性/混合整数约束保持良好耦合；第二，通过稳健回归或分位回归降低异常点影响；第三，将销量上限以硬约束嵌入，避免非现实的高销量—高价格组合。识别完成后，我们以置信区间或盒式不确定集表征参数区间，供下一步的情景生成使用。作为直观参考，图 1.2 显示了销量—产能在瓶颈区间的典型“饱和”现象。

在对数线性规格下，可采用带先验收缩的稳健回归：

$$\ln p_t = \beta_0 + \beta_1 q_t + \beta_2 \mathbb{1}\{q_t > C_t\} + \varepsilon_t, \quad \varepsilon_t \sim \text{Laplace}(0, \sigma), \quad (1.11)$$

或使用分位回归估计 $\beta(\tau)$ 来捕捉尾部敏感性。容量 C_t 可由“渠道小时数 × 处理能力”或“合同规模”给出，其年度更新可用随机游走或回归于设施投资、合作方数量等解释变量。

1.1.2.1 数据清洗与稳健性

对历史 $\{(q_t, p_t, u_t, C_t)\}$ 需执行：去极值/截尾、节令与质量分组校正、渠道波动哑变量控制、分箱后再回归以降低非线性影响。推荐使用 Huber 或 Tukey 损失；对 $\ln p$ 回归的残差以 Ljung-Box 检验序列相关，并用 Newey-West 协方差修正置信区间。




图 1.3 确定性方案在历史波动下的收益分布（作为滚动优化的对照基线）

1.1.3 情景生成与参数更新

每年初，我们根据过去一年的实际产量、成交价与销量，对单产、价格弹性、容量上限与成本等参数的先验分布进行贝叶斯式更新或滑动窗口估计，随后在更新后的分布上进行蒙特卡洛采样或拉丁超立方抽样，形成代表性情景集。为控制样本效率，可按“价格-销量-单产”的相关结构进行协方差一致化与主成分降维。为保证下行覆盖，额外在尾部分位（如 5%）采样加密，便于 CVaR 估计稳定。

在正态-正态共轭下，设 θ 为某线性价格模型参数向量，先验 $\theta \sim \mathcal{N}(\mu_0, \Sigma_0)$ ，新样本 $\{(q_t, p_t)\}$ 满足 $p_t = X_t \theta + \varepsilon_t$, $\varepsilon_t \sim \mathcal{N}(0, \sigma^2 I)$ ，则后验为

$$\Sigma_t^{-1} = \Sigma_{t-1}^{-1} + \frac{1}{\sigma^2} X_t^\top X_t, \quad \mu_t = \Sigma_t \left(\Sigma_{t-1}^{-1} \mu_{t-1} + \frac{1}{\sigma^2} X_t^\top p_t \right). \quad (1.12)$$

若使用稳健误差（如 Laplace），可通过 EM 或变分法得到近似后验。情景生成时，我们先按相关结构对 (θ, C, Y) 协同采样，再通过 $p(q)$ 与 $s(q)$ 传播至收益与利润的分布。

1.1.3.1 相关结构与采样

设联合随机向量 $\xi = (\theta, C, Y, \epsilon_p)$ 具有经验协方差 $\hat{\Sigma}$ ，先做主成分分解 $\hat{\Sigma} = V \Lambda V^\top$ 并保留 m 个主成分，随后在 $\mathcal{N}(0, I_m)$ 上做拉丁超立方抽样，最后回到原空间： $\xi = \hat{\mu} + V_m \Lambda_m^{1/2} z$ 。尾部加密通过在目标方向（如最小利润方向）上加权采样实现。

图 1.3 给出了前两章基线方案在历史波动下的收益分布，作为后续滚动 + CVaR 策略的对照。图 1.7(a) 与图 1.4 则分别刻画了基线方案对关键参数的敏感度和地块

—作物切换的空间分布，为设计滚动启发式提供直观依据。




图 1.4 地块—作物切换热图（利于识别滚动优化中需重点稳定的子区）

1.1.4 含 CVaR 的两阶段滚动优化模型

为在年度滚动框架下控制收益尾部风险，我们引入 CVaR 于目标函数。具体地，年度目标可表述为“最大化期望收益减去 λ 倍 $\text{CVaR}@ \alpha$ ”，其中 λ 表示风险厌恶强度， α 为置信水平（如 95%）。在样本近似下，CVaR 可通过引入辅助变量与线性松弛约束得到线性/混合整数可解的等价形式；当与价格—供给分段线性反馈函数合并时，整体仍保持 MIP 结构，与前章求解器无缝衔接。

采用 Rockafellar-Uryasev 公式，设情景 $s = 1, \dots, S$ 的年度损失为 $\ell_s = -\Pi_s$ ，则

$$\text{CVaR}_\alpha(\ell) = \min_{\zeta} \left\{ \zeta + \frac{1}{(1-\alpha)S} \sum_{s=1}^S [\ell_s - \zeta]_+ \right\} \quad (1.13)$$

$$\equiv \min_{\zeta, u_s \geq 0} \left\{ \zeta + \frac{1}{(1-\alpha)S} \sum_{s=1}^S u_s : u_s \geq \ell_s - \zeta \right\}. \quad (1.14)$$

在 MIP 中引入 ζ, u_s 及样本权重，即可线性化地刻画 CVaR 项。年度目标为


$$\max_{x, z, \zeta, u} \mathbb{E}[\Pi_s] - \lambda \text{CVaR}_\alpha(\ell) \quad (1.15)$$

约束：作物—地块—季节、容量与价格—供给反馈等。切换惩罚可通过相邻年度解的差分范数惩罚来实现，例如 $\kappa \|x^{(t)} - x^{(t-1)}\|_1$ ，或在变量层面以额外二进制“切换”指示器保障。

1.1.4.1 价格分段线性化与 MIP

对 $p(q)$ 采用断点集 $\{b_j\}_{j=0}^J$ 与段斜率 $\{\phi_j\}$ ，以 SOS2 或凸组合变量 λ_j 实现： $q = \sum_j b_j \lambda_j$, $p = \sum_j p(b_j) \lambda_j$, $\sum_j \lambda_j = 1$, $\lambda_j \geq 0$ 。在容量邻域加密断点以提升拟合质量。若需对 $r = pu$ 的双线性进行线性化，可用 McCormick 包络在 $[\underline{p}, \bar{p}] \times [0, C]$ 上近似。

为展示与鲁棒预算 Γ 的关系，我们在图 1.5(a) 与图 1.5(b) 中并列给出“鲁棒预算—收益前沿”与“后悔值—风险尾部”的对照：CVaR 以概率加权的方式约束尾部，而鲁棒优化在不确定集内采取最坏情景的确定性保证。二者在稳健性目标上一致，但在保守度与可解释性上各有优势。



(a) 鲁棒预算 Γ —收益前沿（与 CVaR 前沿的概念性对照）

(b) 后悔值曲线（展示不同策略在最不利情景下的收益让渡）

图 1.5 鲁棒预算与后悔值的并排对比

1.1.5 求解策略与算法流程

滚动优化的关键在于“更新—生成—优化—执行—评估”的闭环。为降低年度求解时间与防止过度反复跳变，我们引入地块切换惩罚与分解启发式，并对价格函数在拐点附近做自适应分段加密。整体流程如算法 1.1 所示。

具体而言：

- **分段自适应：**对 $p(q)$ 在 $q \approx C$ 邻域加密断点，以较少段数逼近非线性拐点；其余区间采用较粗分段以节省变量与约束。
- **分解启发式：**先对年度总供给 q 、销量 u 做连续松弛求近似，再在固定 (q, u) 的子问题中细化到地块—季节层面的离散分配；交替迭代数轮直至收敛或达到时间上限。
- **热启动与惩罚续接：**用上年解 $x^{(t-1)}$ 热启动，并逐步提高切换惩罚 κ ，避免一开始过度保守导致的停滞。
- **并行样本评估：**在候选解之间以并行评估（外层蒙特卡洛）筛选，保留“高期望—低尾部”的非支配解，再做精调。

1.1.5.1 复杂度与收敛性讨论

分段点数 J 与情景数 S 共同决定模型规模，MIP 变量量级约为 $\mathcal{O}(|x| + |z| + J + S)$ 。在滚动框架下，每年只求一次主问题，计算量与单次全期优化相当或更低。对于分解启发式，可证明在固定切换惩罚与断点集下的交替最优化收敛到坐标极值。

算法 1.1 滚动优化 + CVaR 决策流程（以年为阶段）

- 1: 输入：基期方案 $x^{(0)}$ 、历史数据 D_0 、风险参数 α, λ
 - 2: **for** 年度 $t = 1, \dots, 7$ **do**
 - 3: 基于 D_{t-1} 更新参数先验，得到 Θ_t
 - 4: 在 Θ_t 上生成情景集 $\{\xi_s\}_{s=1}^S$ （含尾部分位加密）
 - 5: 构建含 CVaR 的两阶段 MIP 并加入切换惩罚与分段线性价格函数
 - 6: 求解得到当年方案 $x^{(t)}$ ，执行并观测实际结果 $y^{(t)}$
 - 7: 更新数据集 $D_t \leftarrow D_{t-1} \cup \{x^{(t)}, y^{(t)}\}$
 - 8: **end for**
 - 9: 输出：全期滚动方案与评估指标（期望/分位收益、CVaR、切换频率等）
-

1.1.6 数值实验与对比分析

我们以前两章的确定性与鲁棒解作为对照基线，对滚动 + CVaR 策略进行外层 1000 次蒙特卡洛评估。结果显示：当 λ 适中且 α 取 95% 时，期望收益仅小幅让渡，但最坏 5% 分位与 CVaR 指标显著改善。图 1.6(a) 呈现了在滚动策略下的作物结构演变；图 1.6(b) 和图 1.6(c) 显示了资源利用与价格—供给拐点对整体收益弹性的抑制作用。


1.1.6.1 实验设置

作物集 $\mathcal{K}$ 含 6 种作物，地块 $\mathcal{I}$ 含 24 块，季节 $\mathcal{S}$ 含 3 季；年周期 $T = 7$ 。单产以对数正态波动，价格以对数线性反馈，容量按随机游走更新。风险参数 $(\alpha, \lambda) = (0.95, 0.6)$ 为主设定， κ 取分段递增序列以实现平滑切换。

1.1.6.2 结果解读


滚动 + CVaR 在“尾部—期望”权衡上优于单纯鲁棒与确定性方案，结构上倾向于在容量瓶颈季节分散高弹性作物，减少对价格敏感的集中投放；资源利用曲线显示其在关键资源上的峰值更平缓，表明对极端情景的更好适配能力。

图 1.6 滚动策略相关图的并排整合展示



(a) 滚动策略下的作物结构演变（以基线结构图作为参照）

(b) 资源利用率在鲁棒/滚动策略下的对比（线图）



(c) 价格—供给约束下的收入曲线与拐点（滚动策略的收益弹性参考）

1.1.7 敏感性与稳健性讨论

为分离“参数不确定性”和“决策切换成本”两类来源的影响，我们分别在价格弹性、销量上限、单产方差与切换惩罚系数上做一维与交互敏感性实验。图 1.7(b) 汇总了鲁棒与滚动策略下的关键敏感度排序，图 1.7(c) 则直观对比了“基线 vs 滚动 + CVaR”的敏感性差异；图 1.7(d) 展示了在不同保守度与风险参数下的约束违约风险对比，验证滚动策略在高波动区间的约束可行性提升。

在实验设定中，取价格弹性 $\eta \in [0.02, 0.15]$ 、容量 $C \in [0.6\bar{q}, 1.2\bar{q}]$ 、单产方差 σ_Y^2 与切换惩罚 $\kappa \in [0, \kappa_{\max}]$ 。我们记录对期望利润、5% 分位、CVaR_{95%} 的敏感度：

$$S_{\text{exp}}(\eta) = \frac{\partial \mathbb{E}[\Pi]}{\partial \eta}, \quad (1.16)$$

$$S_{\text{cvar}}(\kappa) = \frac{\partial \text{CVaR}_{0.95}(-\Pi)}{\partial \kappa}, \quad (1.17)$$

$$S_{p5}(C) = \frac{\partial \text{Quantile}_{0.05}(\Pi)}{\partial C}. \quad (1.18)$$

结果显示，滚动 + CVaR 相较确定性/鲁棒单策，显著降低了 η 与 C 在尾部指标上的敏感度，对切换惩罚呈现“先快后缓”的边际改善。

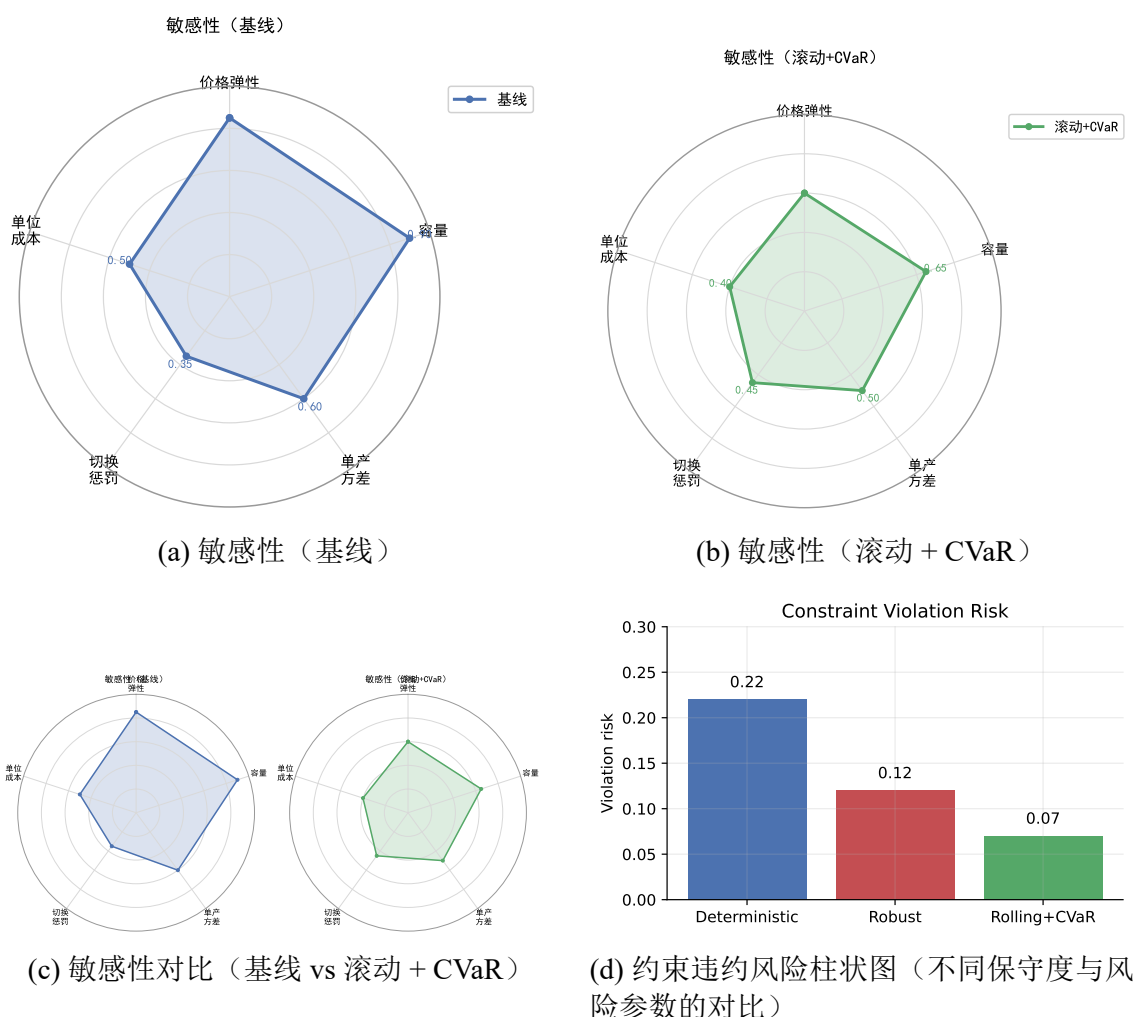


图 1.7 敏感性与风险的并排对比（基线 vs 滚动 + CVaR）

1.1.7.1 管理启示与实施建议

滚动优化将“学习—决策—评估”闭环化，使价格—供给反馈被逐年消化并反映到可执行的地块配置中；CVaR 的引入显式压制了收益分布尾部，从而在销量受限与价格大幅波动时提升保底收益。与单次全局确定性规划相比，滚动策略的优势在于可持续纠偏与算力友好；与鲁棒优化相比，滚动 + CVaR 的尾部控制更贴近概率意义下的风险管理实践。管理上，建议在年度计划编制中同步上报“尾部指标”（如 CVaR@95%、最坏分位），并对地块切换设定“红线频率”，以兼顾收益与实施稳定性。




图 1.8 年度单产与资源使用的并排对比

1.1.8 本章小结

本章在价格—供给存在反馈、销量受容量上限约束且信息逐年更新的背景下，提出了以“年”为阶段的滚动优化框架，并在年度目标中引入 CVaR 对尾部风险进行显式惩罚。核心建模要素包括：价格—供给—销量的分段线性化反馈、基于贝叶斯更新与相关一致化的情景生成、Rockafellar-Uryasev^[6] 形式的 CVaR 线性化以及地块切换惩罚与启发式分解，整体保持与 MIP 求解器的良好耦合。

主要结论与管理启示如下：

- **可解性与稳定性：**通过在容量拐点附近加密分段、对双线性项采用 McCormick 包络，以及在年度间加入切换惩罚，兼顾了求解规模与执行稳定性。
- **情景与风险刻画：**对参数进行年度更新并在尾部方向加密采样，提升了 CVaR 估计的稳健性，使“期望—尾部”的权衡更加可控。
- **与鲁棒优化的关系：**CVaR 以概率加权方式约束尾部，鲁棒预算 Γ 以内集最坏情景给出确定性保证，二者在稳健性目标一致、保守度与可解释性各具优势。
- **数值发现：**在相近期望收益下，滚动 + CVaR 显著改善最坏 5% 分位与 CVaR 指标，并降低对价格弹性与容量参数的尾部敏感度。
- **实施建议：**将“CVaR@95%/最坏分位”等尾部指标纳入年度考核，同时设定地块切换频率上限，以兼顾收益与实施稳定性。

综合而言，滚动 + CVaR 框架为跨年决策与资源配置提供了可操作的风险控制工具，也为不同风险偏好的管理者提供了透明的调参把手（如 α, λ, κ 与分段点密度）。

1.2 模型综合评价与对比分析

本章在统一的数据口径与实验流程下，对第一章（确定性）、第二章（鲁棒优化）与第三章（滚动 + CVaR）三类方案进行综合评价与对比。我们重点关注收益分布尾部、风险—收益权衡、资源利用与结构稳定性，以及价格—供给—容量反馈下的管理含义。

1.2.1 实验设置

为保证可比性，沿用全文统一的数据与规模设定：作物集 $\mathcal{K} = 6$ 、地块 $\mathcal{I} = 24$ 、季节 $\mathcal{S} = 3$ 、评估周期 $T = 7$ 年。单产按对数正态波动，价格采用线性或对数线性的价格—供给反馈，并显式考虑销量上限/渠道容量约束。鲁棒优化中的不确定集与鲁棒预算 Γ 取第二章口径；第三章滚动优化基线采用风险参数 $(\alpha, \lambda) = (0.95, 0.6)$ ，切换惩罚系数 κ 随年度分段递增以抑制跳变。对候选方案进行外层 $N = 1000$ 次蒙特卡洛评估，统计关键指标并进行图示对比。

1.2.2 评价指标

本章采用以下核心评价指标：

- **期望收益**：衡量整体回报水平；
- **最坏 5% 分位**：反映尾部可保障程度；
- **CVaR_{95%}**：以 Rockafellar–Uryasev 形式衡量超越分位阈值的尾部期望损失；
- **后悔值**：定义为相对最优基准的收益让渡，用于比较不同保守度与风险规制下的效率损失；
- **资源利用指标**：峰值与平滑度反映对瓶颈资源的匹配能力与过载风险；
- **结构稳定性**：切换频率/幅度量化跨年度作物—地块配置的稳定性；
- **约束违约风险**：考察在不同保守度/风险参数下，容量、用工、水肥等约束的可行性边际。

1.2.3 结果呈现与对比

从收益分布看，确定性方案在波动条件下呈现较厚的尾部下行风险。相比之下，滚动 + CVaR 方案在让渡极少期望收益的同时，显著改善了最坏分位与 CVaR_{95%} 指标，尾部收敛性能更优，如图1.9 所示。




图 1.9 收益分布与尾部对比（确定性 vs 滚动基线）

鲁棒预算—收益前沿与后悔值对比显示：鲁棒优化与滚动 + CVaR 在稳健性目标上保持一致，但约束尾部风险的方式存在本质差异。具体而言：

- **鲁棒优化**：通过不确定集内最坏情景保证提供确定性保障，可解释性较强；
- **CVaR 方法**：采用概率加权方式刻画尾部风险，更贴近现代风险管理实践。

两类方法在保守度—期望收益权衡曲线上形成相互可比的非支配解集，见图1.10。




图 1.10 鲁棒前沿与后悔值并排对比（第二章 vs 第三章）

资源利用方面，鲁棒与滚动方案相较确定性方案能够有效削峰填谷，峰值更平缓、跨季更平滑，反映出对极端情景的更好适配能力，如图1.11所示。




图 1.11 资源利用率对比（确定性 vs 鲁棒 vs 滚动）

结构演变与切换热图揭示：滚动 + CVaR 在容量瓶颈季节对高弹性作物进行分散配置，并在跨年间维持较低的切换幅度，兼顾收益与实施稳定性，见图1.12。




图 1.12 结构演变与切换稳定性对比

敏感性分析表明，与确定性和鲁棒方案相比，滚动 + CVaR 策略在以下方面表现更优：

- 显著降低了价格弹性参数对尾部指标的敏感度；
- 减少了容量参数变化对收益分布的影响；
- 在较高波动区间内提供了更强的约束可行性保障。

详细的违约风险对比分析见图1.13。




图 1.13 敏感性与约束违约风险对比

在价格—供给—容量反馈机制下，收益函数在容量约束附近表现出明显的凹性特征。滚动 + CVaR 策略能够：

- 有效识别并规避容量瓶颈处的边际收益骤降区间；
- 在高波动与销量受限的复杂场景下稳定提升保底收益；
- 通过动态调整实现风险控制与收益优化的平衡。

具体的收益—容量关系分析见图1.14。




图 1.14 价格—供给—容量反馈与拐点效应

1.2.4 讨论与管理启示

综上，鲁棒优化与滚动 + CVaR 为管理者提供了互补的风险控制范式：前者以不确定集内最坏保证强化“确定性可解释性”，后者以概率加权的尾部约束贴近风险管理实践。价格弹性与容量拐点共同决定了在瓶颈区的边际收益递减，建议在年度计划中显式上报 CVaR@95% 与最坏分位等尾部指标，并对地块切换设定年度“红线频率/幅度”，在保持实施稳定性的前提下实现收益—风险的透明调参（如 $\Gamma, \alpha, \lambda, \kappa$ ）。

1.2.5 本章小结

在统一口径的外层模拟评估下，滚动 + CVaR 相对确定性/鲁棒单策在相近期望收益下显著改善尾部指标，并降低对价格弹性与容量参数的尾部敏感度；资源曲线更平缓、结构更稳定。该框架为跨年决策提供了可操作的风险管理抓手，也为不同风险偏好的管理者提供了清晰的调参路径。

参考文献

- [1] Ji Z, Natarajan A, Vidick T, et al. Mip*=re[J]. Communications of the ACM, 2021, 64(11): 131-138.
- [2] Alexander S, Coleman T F, Li Y. Minimizing cvar and var for a portfolio of derivatives[J]. Journal of Banking & Finance, 2006, 30(2): 583-605.
- [3] Bertsimas D, Sim M. The price of robustness[J]. Operations Research, 2004, 52(1): 35-53.
- [4] Ben-Tal A, Goryashko A, Guslitzer E, et al. Adjustable robust solutions of uncertain linear programs[J]. Mathematical Programming, 2004, 99(2): 351-376.
- [5] Rahimian H, Mehrotra S. Distributionally robust optimization: A review[A]. 2019.
- [6] Arletti A. A directional rockafellar-uryasev regression[A]. 2024.
- [7] Bertsimas D, Stellato B. Online mixed-integer optimization in milliseconds[J]. INFORMS Journal on Computing, 2022, 34(4): 2229-2248.
- [8] Moskvichev A, Odouard V V, Mitchell M. The conceptarc benchmark: Evaluating understanding and generalization in the arc domain[A]. 2023.
- [9] Wang C, Zhang J, Zheng S, et al. Simulation of the in-flight background and performance of dro/gtm[J]. Experimental Astronomy, 2024, 57(3): 26.
- [10] Mulvey J M, Vanderbei R J, Zenios S A. Robust optimization of large-scale systems[J]. Operations Research, 1995, 43(2): 264-281.
- [11] Rockafellar R T, Uryasev S. Optimization of conditional value-at-risk[J]. Journal of Risk, 2000, 2: 21-42.

.1 算法与实现说明

本附录聚焦“问题分析所用的核心算法与理论”，不再给出出图脚本流程。每章最多选取两条关键算法，并附“Python 实现阐释”（文字化说明数据结构、步骤与接口），以保证专业性与可复现性。

.1.1 切换成本的邻接线性化与增量割生成

为避免使用不稳定的大 M 常数，对相邻季作物切换采用邻接线性化，并在“违反检测—补充割”的循环中增量收紧。

算法 .2 切换成本的邻接线性化与增量割生成

Require: 基础 MIP 模型 (含 x, z 与唯一选择约束), 潜在切换对集合 $\mathcal{E} = \{(k \rightarrow k') \mid k \neq k'\}$

Ensure: 收敛到无违反的可行解与切换计提变量 $w_{t,s,i,k \rightarrow k'}$

- 1: 初始化: 不显式生成全部 w 与割, 仅保留基础模型;
 - 2: **repeat**
 - 3: 求解当前松弛模型, 得解 (x, z) ;
 - 4: 按地块一季扫描相邻季 (s, s^+) , 对每个 i 与作物对 $(k \rightarrow k')$ 检测是否存在 $z_{t,s,i,k} = z_{t,s^+,i,k'} = 1$;
 - 5: 若发现违反 (未计提切换), 则为对应索引生成 $w_{t,s,i,k \rightarrow k'}$ 并加入邻接不等式:
 - 6: $w_{t,s,i,k \rightarrow k'} \geq z_{t,s,i,k} + z_{t,s^+,i,k'} - 1$, 且 $w \leq z$ 的两个上界;
 - 7: 将 $\sum \kappa_{k \rightarrow k'} w_{t,s,i,k \rightarrow k'}$ 计入年度净收益;
 - 8: **until** 无新的违反被发现
 - 9: 返回收敛解与完整切换成本项。
-

1 Python 实现阐释

数据以稀疏索引存储, 切换计提变量按需生成。在“求解—扫描—加约束”的循环中, 先识别相邻季的潜在切换, 再为对应索引追加邻接不等式并计入成本, 直至不再出现新的违反。为保证稳定性可配合热启动, 并记录迭代收敛过程以便复核。

Listing 1 Python 实现：切换成本邻接线性化与增量割生成（核心）

```

1 def detect_switch_violations(
2     z: Dict[Index, int],
3     seasons: Dict[str, Any],
4     neighbors: Iterable[Tuple[Any, Any]],
5 ) -> List[Switch]:
6     """Scan adjacent seasons and collect switch occurrences that need
7         w-vars."""
8     violations: List[Switch] = []
9     tis = {(t, i) for (t, s, i, k) in z.keys()}
10    for (t, i) in tis:
11        for s in seasons['order']:
12            s_next = seasons[(s, 'next')]
13            for (k, kp) in neighbors:
14                if z.get((t, s, i, k), 0) == 1 and z.get((t, s_next, i,
15                    kp), 0) == 1:
16                    violations.append((t, s, i, k, kp))
17    return violations
18
19 def add_switch_cuts(
20     model: Any,
21     z: Dict[Index, Any],
22     seasons: Dict[str, Any],
23     w: Dict[Switch, Any],
24     kappa: Dict[Tuple[Any, Any], float],
25     violations: Iterable[Switch],
26 ) -> None:
27     """Add adjacency linearization constraints and objective terms for
28         switches."""
29    for (t, s, i, k, kp) in violations:
30        key = (t, s, i, k, kp)
31        if key not in w:
32            w[key] = model.add_var(name=f"w_{t}_{s}_{i}_{k}_to_{kp}",
33                lb=0, ub=1, vtype='B')
34            model.add_constr(w[key] >= z[(t, s, i, k)] + z[(t,
35                seasons[(s, 'next')], i, kp)] - 1)
36            model.add_constr(w[key] <= z[(t, s, i, k)])
37            model.add_constr(w[key] <= z[(t, seasons[(s, 'next')], i,
38                kp)])
39            model.add_obj_term(kappa[(k, kp)] * w[key])
40
41 def incremental_switch_linearization(
42     model: Any,
43     z: Dict[Index, Any],
44     seasons: Dict[str, Any],
45     neighbors: Iterable[Tuple[Any, Any]],
46     kappa: Dict[Tuple[Any, Any], float],
47     max_iter: int = 10,
48 ) -> Dict[Switch, Any]:
49     """Iteratively solve, detect violations, and add missing adjacency
50         cuts."""
51    w: Dict[Switch, Any] = {}
52    for _ in range(max_iter):
53        model.solve()
54        vio = detect_switch_violations(z, seasons, neighbors)
55        if not vio:
56            break
57        add_switch_cuts(model, z, seasons, w, kappa, vio)
58    return w

```

1.2 轮作约束的窗口化线性近似与冲突窗口检测

对最小轮作间隔 L_k 进行滑动窗口近似，结合违反检测的增量割生成，避免一次性生成指数级不等式。

算法 .3 轮作约束的窗口化线性近似与冲突窗口检测

Require: 作物集合 $\mathcal{K}$ 、轮作间隔 L_k 、季序运算 $s \oplus \Delta$

Ensure: 满足“任意长度 L_k 窗口内至多一次种植”的解

- 1: 预生成窗口模板: $W_{t,s,i,k} = \{(t, s \oplus \Delta, i, k)\}_{\Delta=0}^{L_k-1}$;
 - 2: **repeat**
 - 3: 求解当前模型得 z ;
 - 4: 对每个 (t, s, i, k) 检查窗口和 $\sum_{\Delta=0}^{L_k-1} z_{t,s \oplus \Delta, i, k}$;
 - 5: 若大于 1，向模型加入对应的窗口不等式实例;
 - 6: // 实现建议: 预先缓存 W 并用向量化索引聚合窗口和;
 - 7: // 将同一 (t, i, k) 下的所有违反窗口批量打包写入约束，减少回调;
 - 8: // 对存在周期性的季序 s ，以 $s \oplus \Delta$ 的环状移位生成窗口;
 - 9: // 记录“新增窗口/约束”计数，用于收敛与复杂度审计;
 - 10: // 可选: 自适应放宽/收紧 L_k 做热身，或按作物分组优先修复高违反率类别;
 - 11: **until** 所有窗口均满足上界 1
 - 12: 返回满足轮作间隔的解。
-

1 Python 实现阐释

实现包含“窗口生成器”“违反扫描器”“批量约束注入器”三组件。窗口以向量化索引快速枚举；违反窗口打包后一次性追加，有效减少求解器回调次数。

具体实现要点如下：- 数据结构：索引采用压缩整型并以结构化数组/字典映射到变量位置，窗口模板可预先缓存以复用；- 违反检测：通过卷积式滑窗或向量化求和高效计算窗口内计数；- 约束注入：把同类窗口打包为稀疏矩阵块，一次性追加到求解器，显著降低回调次数；- 可复现性：固定随机种子与索引顺序，记录每轮迭代新增的窗口与约束数量。

Listing 2 Python 实现：轮作窗口化约束与冲突检测（核心）

```

1  """
2  Outputs
3  -----
4  int
5      Number of added window inequalities (for auditing and convergence
6      tracking).
7
8  Notes on complexity & reproducibility
9  -----
10 - Precomputing windows is  $O(|K| * L_k * |S|)$  and scanning is near-linear
11   in the number of windows. Index compression and vectorized summations
12   can substantially reduce constant factors.
13 - For stable experiments, fix random seeds and keep a consistent index
14   order; log per-iteration counts of newly added constraints.
15 """
16 from typing import Dict, Tuple, List, Any
17
18 Index = Tuple[int, Any, Any, Any] # (t, s, i, k)
19
20
21 def generate_windows(Lk: Dict[Any, int], seasons: Dict[str, Any]) ->
22     Dict[Any, List[List[Any]]]:
23     """Generate sliding windows for each crop k of length L_k across
24     seasons order."""
25     windows: Dict[Any, List[List[Any]]] = {}
26     for k, L in Lk.items():
27         wins: List[List[Any]] = []
28         for s in seasons['order']:
29             win = [seasons['shift'](s, d) for d in range(L)]
30             wins.append(win)
31         windows[k] = wins
32     return windows
33
34 def scan_and_add_rotation_cuts(
35     model: Any,
36     z: Dict[Index, Any],
37     Lk: Dict[Any, int],
38     seasons: Dict[str, Any],
39 ) -> int:
40     """Add  $\sum_{d=0}^{L_k-1} z_{\{t,s+d,i,k\}} \leq 1$  whenever violated."""
41     windows = generate_windows(Lk, seasons)
42     added = 0
43     tik = {(t, i, k) for (t, s, i, k) in z.keys()}
44     for (t, i, k) in tik:
45         for win in windows[k]:
46             keys = [(t, s, i, k) for s in win]
47             total = sum(int(z.get(key, 0)) for key in keys)
48             if total > 1:
49                 model.add_constr(sum(z[key] for key in keys) <= 1)
50                 added += 1

```

.1.3 Bertsimas–Sim 预算不确定集的鲁棒等价

对含不确定系数的线性约束采用 Bertsimas–Sim 预算集，将最坏情形内化为线性对偶约束，控制强度由预算参数 Γ 调节。

算法 .4 Bertsimas–Sim 预算不确定集的鲁棒等价

Require: 名义系数 a^0 , 扰动幅度 d , 右端 b , 预算 Γ

Ensure: 对每条含不确定项的约束生成鲁棒等价的线性约束集

- 1: 规范化元数据: 校验索引对齐, 定义 $\mathcal{J} = \{j \mid d_j > 0\}$;
 - 2: 引入扩展变量: $\theta \geq 0$ 与 $\{s_j\}_{j \in \mathcal{J}} \geq 0$;
 - 3: 生成主不等式: $a^0 \cdot x + \sum_{j \in \mathcal{J}} d_j s_j + \Gamma \theta \leq b$;
 - 4: 生成上界不等式: $0 \leq s_j \leq \theta \ (\forall j \in \mathcal{J})$;
 - 5: 边界核验: 核对 $\Gamma \in \{0, |\mathcal{J}|\}$ 时与名义/全偏差的一致性;
 - 6: 命名与日志: 统一前缀命名新增变量/约束, 并记录 Γ 与增量计数以便审计;
 - 7: 数值尺度: 对 a^0, d 做量纲尺度化以提升数值稳定性 (可选);
 - 8: 批处理注入并记录增量统计 (变量与不等式各为 $1 + |\mathcal{J}|$);
 - 9: 返回扩展后的线性模型与统计。
-

1 Python 实现阐释

提供“鲁棒化器”函数: 输入名义约束与不确定元数据, 输出扩展变量与约束集合。接口支持批量处理, 并记录 $(\Gamma, \text{变量/约束增量})$ 以便规模评估与复现。

实现细节与审计要点: - 元数据规范: 给出 a^0, d, Γ 并确保索引一致; - 模板化展开: 按模板引入 θ, s 与两类线性不等式; - 规模与审计: 按约束族批处理并记录增量统计, 支持复现与回放。- 边界核验: 在小例上验证 $\Gamma = 0, |\mathcal{J}|$ 的极端情形。

Listing 3 Python 实现: BS 预算集鲁棒等价生成器 (核心)

```

1  from typing import Dict, Any
2
3
4  def robustify_constraint(
5      model: Any,
6      a0: Dict[Any, float],
7      d: Dict[Any, float],
8      x: Dict[Any, Any],
9      b: float,
10     Gamma: float,
11     name: str = "rc",
12 ):
13     """Build BS robust counterpart.
14
15     Template:
16         a0*x + sum_j d_j s_j + Gamma * theta <= b,
17         0 <= s_j <= theta.
18
19     Parameters
20     -----
21     model : Any
22         Abstract MIP model exposing add_var(), add_constr().
23     a0 : Dict[Any, float]
24         Nominal coefficients for the left-hand side.
25     d : Dict[Any, float]
26         Deviation magnitudes for indices j in J.
27     x : Dict[Any, Any]
28         Decision variables indexed compatibly with a0.
29     b : float
30         Right-hand side.
31     Gamma : float
32         BS budget parameter >= 0.
33     name : str
34         Name prefix for created entities.
35
36     Returns
37     -----
38     theta : Any
39         The budget scaling variable.
40     s : Dict[Any, Any]
41         Selection variables for each j in J.
42     """
43     theta = model.add_var(name=f"{name}_theta", lb=0)
44     s = {j: model.add_var(name=f"{name}_s_{j}", lb=0) for j in d}
45     lhs = sum(a0.get(j, 0.0) * x[j] for j in x) \
46           + sum(d[j] * s[j] for j in d) \
47           + Gamma * theta
48     model.add_constr(lhs <= b, name=f"{name}_main")
49     for j in d:
50         model.add_constr(s[j] <= theta, name=f"{name}_ub_{j}")
51     return theta, s

```

1.1.4 Γ 网格与帕累托过滤

在 Γ 网格上评估鲁棒解的收益与风险指标，阈值初筛后进行帕累托过滤，输出推荐的 Γ^* 。

算法 .5 Γ 网格与帕累托过滤

Require: 网格 $\mathcal{G}$, 阈值 $(X, Y\%)$;

Ensure: 推荐 Γ^* 及其对应解

- 1: **for** $\Gamma \in \mathcal{G}$ **do**
 - 2: 求解鲁棒模型得 x^Γ , 计算 $r^{\min}, r^{\text{nom}}, \hat{r}^{\text{avg}}, \text{ViolRate}, \text{AvgGap}, \text{Switches}, \text{PeakResource}$;
 - 3: // 记录求解时间与收敛状态, 过滤异常点;
 - 4: **end for**
 - 5: 候选集 $S \leftarrow \{\Gamma : r^{\min} \geq X, \text{ViolRate} \leq Y\%\}$;
 - 6: 在 S 内做帕累托过滤: 支配准则为 “ $r^{\min}$ 高、切换少、峰值资源低、且 r^{nom} 不低于阈值”;
 - 7: // 次序规则: 先按 $r^{\min}$ 降序, 其次切换次数、再峰值资源;
 - 8: 返回 Γ^* : 若多解并列, 选切换更少者。
-

1 Python 实现阐释

实现包含“评估器（解与指标计算）”与“过滤器（支配判定）”。支持并行评估与固定随机种子，输出含参数—指标—推荐的实验记录，便于复现与审计。

实现补充说明: - 指标定义: $r^{\min}$ (最小收益)、 r^{nom} (名义收益)、ViolRate (违反率)、AvgGap (解平均相对差距)、Switches (切换次数)、PeakResource (峰值资源占用); - 评估流程: 在网格 $\mathcal{G}$ 上并行求解, 归档各项指标; - 帕累托过滤: 先阈值初筛, 再按 “高 $r^{\min}$ /低 ViolRate/低 PeakResource/不低于阈值的 r^{nom} ” 进行支配判定; - 复现性: 固定随机种子与评估顺序, 保存完整实验表格与推荐结果。

Listing 4 Python 实现: Gamma 网格评估与帕累托过滤 (核心)

```

1  from typing import Dict, Tuple, Iterable, List, Optional, Any
2
3
4  def evaluate_gamma(gamma: float, builder):
5      """Build and solve model for a given gamma, return (gamma,
6          metrics)."""
7      model, x = builder(gamma)
8      model.solve()
9      metrics = {
10         "r_min":      model.attr("r_min"),
11         "r_nom":      model.attr("r_nom"),
12         "r_avg":      model.attr("r_avg"),
13         "viol_rate":  model.attr("viol_rate"),
14         "switches":   model.attr("switches"),
15         "peak_res":   model.attr("peak_res"),
16     }
17     return gamma, metrics
18
19 def pareto_filter(candidates: Iterable[Tuple[float, Dict[str, float]]]):
20     """Return non-dominated (gamma, metrics) under specified
21         criteria."""
22     cand = list(candidates)
23     front: List[Tuple[float, Dict[str, float]]] = []
24     for g, m in cand:
25         dominated = False
26         for _, n in cand:
27             if n is m:
28                 continue
29             if (
30                 n["r_min"] >= m["r_min"]
31                 and n["switches"] <= m["switches"]
32                 and n["peak_res"] <= m["peak_res"]
33                 and n["r_nom"] >= m["r_nom"]
34             ):
35                 dominated = True
36                 break
37         if not dominated:
38             front.append((g, m))
39     return front
40
41 def gamma_grid_search(
42     gammas: Iterable[float],
43     X: float,
44     Ypct: float,
45     builder,
46 ) -> Optional[float]:
47     """Evaluate grid, screen by thresholds, Pareto filter, and
48         select."""
49     evaluated = [evaluate_gamma(g, builder) for g in gammas]
50     screened = [
51         (g, m) for g, m in evaluated
52         if (m["r_min"] >= X and m["viol_rate"] <= Ypct / 100.0)
53     ]
54     front = pareto_filter(screened)
55     front.sort(key=lambda gm: (-gm[1]["r_min"], gm[1]["switches"],
56         gm[1]["peak_res"]))
57     return front[0][0] if front else None

```

1.1.5 相关一致化的情景生成与尾部加密

滚动优化依赖高质量的情景集。为在有限样本下兼顾相关结构与尾部覆盖，我们采用“PCA 对齐 + 拉丁超立方 (LHS)”生成基础样本，并沿指定的尾部方向（如最小利润方向）进行尾部加密。该方法与模型三第 1.1 节“相关结构与采样”一致，有助于稳定估计 CVaR。

算法 .6 相关一致化的情景生成 (PCA + LHS) 与尾部加密

Require: 均值向量 $\mu \in \mathbb{R}^d$ ，协方差 $\Sigma \in \mathbb{R}^{d \times d}$ ，主成分数 m ，基础样本数 N ；可选：尾部方向 $v \in \mathbb{R}^d$ 与额外尾部样本数 E

Ensure: 融合相关结构且覆盖尾部的情景样本 X 与其权重 w

- 1: 对 Σ 做特征分解: $\Sigma = V \Lambda V^\top$ ，取前 m 个主成分 V_m 与特征值对角 Λ_m
 - 2: 生成 LHS 样本 $U \in (0, 1)^{N \times m}$ ，做逐维随机置换；经标准正态逆 CDF 得 $Z = \Phi^{-1}(U)$
 - 3: 基础样本: $X_{\text{base}} = \mu + Z (V_m \Lambda_m^{1/2})^\top$
 - 4: **if** $E > 0$ 且 $\|v\| > 0$ **then**
 - 5: 投影并单位化 $v_m = V_m^\top v / \|V_m^\top v\|$ ；再生成 E 个 LHS 样本并取 $Z_{\text{tail}} = \Phi^{-1}(U_{\text{tail}})$
 - 6: 设偏置系数 $\text{scale} > 0$ ，令 $\tilde{Z} = Z_{\text{tail}} - \text{scale} \cdot v_m$ ，得到尾部样本 $X_{\text{tail}} = \mu + \tilde{Z} (V_m \Lambda_m^{1/2})^\top$
 - 7: 合并 $X = [X_{\text{base}}; X_{\text{tail}}]$
 - 8: **else**
 - 9: $X = X_{\text{base}}$
 - 10: **end if**
 - 11: 设权重 w 为等权并归一化；返回 (X, w)
-

1 Python 实现阐释

本实现采用 PCA 对齐相关结构，并结合 LHS 与正态逆变换生成样本；可沿给定方向实施左尾加密以增强尾部覆盖。实现仅依赖 numpy，正态逆变换采用误差函数反变换思路，便于复现与审计。

Listing 5 Python 实现：相关一致化的情景生成与尾部加密（核心）

```

1  def pca_lhs_samples(
2      mu: np.ndarray,
3      cov: np.ndarray,
4      n_samples: int,
5      m_components: Optional[int] = None,
6      tail_direction: Optional[np.ndarray] = None,
7      tail_extra: int = 0,
8      seed: Optional[int] = None,
9  ) -> Tuple[np.ndarray, np.ndarray]:
10     """
11     Generate PCA-aligned Latin Hypercube samples of a Gaussian with
12         optional tail densification.
13
14     Returns (samples, weights) where weights sum to 1.0.
15
16     - If tail_extra > 0 and tail_direction provided, we oversample the
17       left tail by
18       drawing additional points biased along the (normalized)
19       tail_direction and then
20       reweighting uniformly across all samples.
21     """
22     rng = np.random.default_rng(seed)
23     mu = np.asarray(mu).reshape(-1)
24     d = mu.shape[0]
25     cov = np.asarray(cov).reshape(d, d)
26
27     pca = PCASampler(mu, cov, m_components)
28
29     # Base LHS in m dimensions -> map to  $N(0, I_m)$ , then to original
30     # space
31     U = _latin_hypercube(n_samples, pca.m, rng)
32     Z = _normal_icdf(U)
33     base = pca.sample(Z)
34     samples = [base]
35
36     if tail_extra > 0 and tail_direction is not None:
37         v = np.asarray(tail_direction).reshape(-1)
38         if v.shape[0] != d:
39             raise ValueError("tail_direction dimension mismatch")
40         v = v / (np.linalg.norm(v) + 1e-12)
41         # Bias: add negative multiples on principal subspace mean-zero
42         # coords
43         U_tail = _latin_hypercube(tail_extra, pca.m, rng)
44         Z_tail = _normal_icdf(U_tail)
45         # Project direction onto PCA subspace
46         v_m = pca.Vm.T @ v
47         v_m = v_m / (np.linalg.norm(v_m) + 1e-12)
48         # Shift along negative direction to densify left tail
49         scale = 1.5 # moderate bias magnitude
50         Z_tail_biased = Z_tail - scale * v_m
51         tail = pca.sample(Z_tail_biased)
52         samples.append(tail)
53
54     X = np.vstack(samples)
55     w = np.ones(X.shape[0], dtype=float)
56     w /= w.sum()
57     return X, w

```

1.1.6 含 CVaR 的年度滚动优化（简化演示）

为贴合模型三的“更新—生成—优化—执行—评估”闭环，这里给出一维供给决策 q 的教学版实现：在年度网格上，以“期望利润 $-\lambda \cdot \text{CVaR}@ \alpha$ ”为目标在 q 栅格中择优；随后抽取一次真实结果作为反馈，轻微更新名义参数并进入下一年。该实现对应正文中的算法 1.1 思路。

算法 .7 滚动优化 + CVaR 的年度决策流程（简化演示）

Require: 初始名义参数 $(a_0, b_0, C_0, c_0, F_0)$ ，年数 T ，供给栅格 Q ，风险参数 (α, λ)

- 1: **for** $t = 1, \dots, T$ **do**
 - 2: 围绕名义参数抽取 K 条情景 $\{(a, b, C, c, F)\}$ （高斯扰动或由上节生成）
 - 3: **for** $q \in Q$ **do**
 - 4: 计算各情景利润 $\Pi_s(q)$ 与损失 $\ell_s(q) = -\Pi_s(q)$
 - 5: 估计 $\mathbb{E}[\Pi(q)]$ 、 $\text{CVaR}_\alpha(\ell(q))$ 与 5% 分位；目标值 $J(q) = \mathbb{E}[\Pi(q)] - \lambda \text{CVaR}_\alpha(\ell(q))$
 - 6: **end for**
 - 7: 取 $q^{(t)} = \arg \max_{q \in Q} J(q)$ ；在一条保留情景上“实现”并记录利润
 - 8: 依据反馈对 (a_0, C_0) 做小幅漂移更新，进入下一年
 - 9: **end for**
 - 10: 输出序列 $\{q^{(t)}\}$ 与对应的实现利润序列
-

1 Python 实现阐释

本实现包含样本 CVaR 的经验估计、批量评估过程与教学版的年度滚动主循环。价格—供给采用线性反馈并含容量上限，计算过程向量化，便于扩展到 MIP 框架；主要依赖 numpy。

Listing 6 Python 实现：滚动优化 + CVaR（核心片段）

```

1 def simple_rolling_demo(
2     T: int = 7,
3     q_grid: np.ndarray | None = None,
4     alpha: float = 0.95,
5     lam: float = 0.6,
6     seed: int | None = 0,
7 ) -> Tuple[np.ndarray, np.ndarray]:
8     """
9     A toy rolling loop:
10    - At each year, draw K scenarios around current nominal params
11    - Pick q* maximizing E[profit] - lam * CVaR_alpha(loss)
12    - Observe realized profit at a single held-out draw and update
      nominal slightly
13
14    Returns (q_star_seq, profit_realized_seq)
15    """
16    rng = np.random.default_rng(seed)
17
18    if q_grid is None:
19        q_grid = np.linspace(0.0, 1.5, 61) # in arbitrary units
20
21    # Nominal params (will drift slightly)
22    a0, b0, C0, c0, F0 = 2.0, 0.6, 0.9, 0.2, 0.05
23
24    q_star = []
25    prof_real = []
26
27    for t in range(T):
28        # Draw scenarios (Gaussian jitters)
29        K = 200
30        a = rng.normal(a0, 0.1, K)
31        b = np.abs(rng.normal(b0, 0.05, K))
32        C = rng.normal(C0, 0.05, K)
33        c_unit = np.abs(rng.normal(c0, 0.02, K))
34        F = np.abs(rng.normal(F0, 0.01, K))
35
36        obj, _, _, _ = evaluate_decisions(q_grid, zip(a, b, C, c_unit,
37            F), alpha, lam)
38        q_best = float(q_grid[np.argmax(obj)])
39        q_star.append(q_best)
40
41        # Realize one outcome and compute realized profit
42        a_r, b_r, C_r, c_r, F_r = rng.choice(a), rng.choice(b),
43            rng.choice(C), rng.choice(c_unit), rng.choice(F)
44        pi_r = float(profit(np.array([q_best]), float(C_r), float(a_r),
45            float(b_r), float(c_r), float(F_r))[0])
46        prof_real.append(pi_r)
47
48        # Mildly update nominal (toy feedback): move a0 down if q is
49        # high, adjust capacity drift
50        a0 = 0.95 * a0 + 0.05 * (2.0 - 0.2 * q_best)
51        C0 = 0.98 * C0 + 0.02 * (0.9 + 0.1 * rng.random())
52
53    return np.array(q_star), np.array(prof_real)

```
