

□□□□□ 509403

□□□□□□□□□□□□□□□□□□□□

□□□□□□□□□□

□□□□

□□□□□ □□□□□

□□□□□□□ CQ-02 □□□□□□□□□□□□□□□□□□□□

□□□□□□□ □□□□□□□□□□

□□□□□ □□□□□□□□□□□□□□□□□□□□
□□□□□□□□□□□□□□

□□□□□ □□□□□□□□□□


Abstract

This testing scheme aims to conduct a systematic and comprehensive research evaluation of the core algorithms of the multimodal dialect Acoustic intelligent teaching platform, verifying their performance and stability in complex dialect processing and intelligent teaching scenarios. The platform comprises four key modules: the multimodal dialect Acoustic knowledge graph, the contextual intelligent agent reasoning system, the adaptive multi-step retrieval generation model, and the phonology self-evolution generation and calibration model. The testing methodology follows the principle of “function coverage + performance quantification + scenario simulation,” ensuring validation from functional correctness to real-task performance.

The testing process adopts a hybrid evaluation approach that combines automated batch testing with expert human review. Automated testing uses scripts to batch process multimodal inputs (text, speech, and phonological rules), calculating metrics such as accuracy, recall, F1 score, and response latency; human review involves inviting dialectology and linguistics experts to score output quality and analyze errors. The experiments include baseline comparisons (e.g., removing the knowledge graph) and ablation tests (e.g., removing acoustic or textual features), while tracking changes in the model’s adaptability and self-evolution performance across multiple iterations.

The test data covers dialect samples from multiple regions, audio with standard and non-standard accents, low-frequency words, polyphonic characters, and noisy speech inputs, all accompanied by structured metadata descriptions. The results are presented through data tables and visualizations to provide a basis for algorithm optimization.

Keywords: Multimodal Testing Method; Baseline Comparison Experiment; Ablation Analysis; Automated Batch Testing and Expert Review; Performance Visualization Analysis



Agent 环境搭建
Agent 环境搭建
Agent 环境搭建
Agent 环境搭建
Agent 环境搭建

1.3 环境搭建

1.3.1 环境搭建

环境搭建
环境搭建
环境搭建

1.1 环境搭建

配置	配置
处理器	Intel Core i9-14900K
内存	32GB RAM
显卡	NVIDIA Tesla GPU 1 配置
存储	2TB SSD 配置

环境搭建
环境搭建
环境搭建

1.3.2 环境搭建

环境搭建 Ubuntu 20.04 LTS 64 配置

[illegible][illegible][illegible]

2.4 ☐ ☐ ☐ ☐ ☐ ☐

??

[illegible][illegible]

□ 2 □ □□□□□□

□ 2.1 □□□□□□□□□

□□□□	□□	□□	□□□□	□□□□□□
QA-001	□□□□□□□ □□□□	□□□□□“□□□□ ‘□’□□□□□□□□ □□□□□□□”	□□□□□□□□□□ □□□□□□□“□”□ □□□□□□□□□□ □□□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□□
QA-002	□□□□□□□ □□□□	□□□□□□“□□‘□ □’□□□□□□□□□ □□□□□□□□□□ □□”	□□□□□□□□□□ IPA □□□□□□□ □□□□□□□□□□ □□□□□□□□□□ □□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□□□□ □□□□□□□□
PD-001	□□□□□□□ □□□□	□□□□□“□ (ru4)” □□□□ [-k] □□□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□□□□ □□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□□
PD-002	□□□□□□□ □□	□□□□□□□□“□ □”□□□□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□	□□□□□□□□□□ □□□□□□□□□□ □□□□□□□

实验结果

3.3.1 实验结果

在 Dialect-QA 数据集上，Dialectus 的 F1 分数为 7.1%，而 LLM 的 F1 分数为 15.4%。在 40 个测试样本中，Dialectus 的 F1 分数为 76.8%，而 LLM 的 F1 分数为 65.7%。在 Standard RAG 数据集上，Dialectus 的 F1 分数为 62.4%，而 LLM 的 F1 分数为 62.4%。

表 3.1 Dialect-QA 数据集上的实验结果

模型	EM(%)	F1(%)	ROUGE-L
Vanilla LLM (LLM)	15.4	23.1	20.5
Standard RAG	42.8	65.7	51.3
Single-Agent (LLM)	48.1	60.2	48.9
Dialectus (LLM)	55.3	76.8	62.4

在 Single-Agent 数据集上，LLM 的 F1 分数为 68.3%，而 Standard RAG 的 F1 分数为 87%。在 Dialectus 数据集上，Dialectus 的 F1 分数为 89.6%，而 LLM 的 F1 分数为 21.3%。

在 Pronunciation-Diag 数据集上，Generator_{θ₀} 的 F1 分数为 68.3%，而 (Generator+Self-Evolve) 的 F1 分数为 89.6%。在 21.3% 的测试样本中，Generator_{θ₀} 的 F1 分数为 64%，而 (Generator+Self-Evolve) 的 F1 分数为 87%。

表 3.2 Pronunciation-Diag 数据集上的实验结果

模型	LLM F1(%)	Standard RAG F1(%)	Dialectus F1(%)
Generator _{θ₀}	68.3	64	72
Generator+Self-Evolve	89.6	87	91

在 RAFT 数据集上，Dialectus 的 F1 分数为 89.6%，而 LLM 的 F1 分数为 21.3%。

我们使用以下提示词来评估模型的性能：“请根据提供的上下文信息，回答以下问题。如果无法回答，请返回‘无法回答’。”

3.3.2 实验结果

我们使用以下提示词来评估模型的性能：“请根据提供的上下文信息，回答以下问题。如果无法回答，请返回‘无法回答’。”

Dialect-QA 模型在 Dialectus 数据集上的性能为 4.88/5，而 Vanilla LLM 模型的性能为 3.1/2.9。Single-Agent 模型的性能为 4.3/4.2。Dialectus 模型在 Dialectus 数据集上的性能为 4.88/5，而 Vanilla LLM 模型的性能为 3.1/2.9。Single-Agent 模型的性能为 4.3/4.2。


我们使用以下提示词来评估模型的性能：“请根据提供的上下文信息，回答以下问题。如果无法回答，请返回‘无法回答’。”

3.3.3 实验结果

我们使用以下提示词来评估模型的性能：“请根据提供的上下文信息，回答以下问题。如果无法回答，请返回‘无法回答’。”

表 3.3 Dialect-QA 模型在 Dialectus 数据集上的性能


模型	准确率		相关性 (1-5)		
	EM	F1 Score	ROUGE-L	精度	召回
Vanilla LLM	15.4	23.1	20.5	3.12	2.89
Standard RAG	42.8	55.3	48.9	4.15	4.05
Single-Agent	48.1	60.2	51.3	4.33	4.21
Dialectus (Ours)	65.7	76.8	62.4	4.88	4.81



3.3 方言问答系统 Dialect-QA F1 性能分析

系统性能提升分析

系统性能提升分析



3.4 3.4 音系自进化模型 Generator+Self-Evolve 性能分析

Generator θ_0 68.3% 89.6% F1 性能提升 21.3% 95%

3. **Agent**

Agent

LLM

5.

[illegible]